

UNIVERSIDADE FEDERAL DE SANTA MARIA
CENTRO DE TECNOLOGIA
CURSO DE GRADUAÇÃO EM ENGENHARIA DE COMPUTAÇÃO

Luis Felipe de Deus

**ESTIMATIVA DA PRESSÃO ARTERIAL ATRAVÉS DE MODELOS DE
INTELIGÊNCIA ARTIFICIAL NO PROCESSAMENTO DE SINAIS DE
FOTOPLETISMOGRAFIA**

Santa Maria, RS
2020

Luis Felipe de Deus

**ESTIMATIVA DA PRESSÃO ARTERIAL ATRAVÉS DE MODELOS DE INTELIGÊNCIA
ARTIFICIAL NO PROCESSAMENTO DE SINAIS DE FOTOPLETISMOGRAFIA**

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Engenheiro de Computação**.

ORIENTADOR: Prof. Cesar Augusto Prior

Santa Maria, RS
2020

©2020

Todos os direitos autorais reservados a Luis Felipe de Deus. A reprodução de partes ou do todo deste trabalho só poderá ser feita mediante a citação da fonte.

End. Eletr.: dedeus.f.l@gmail.com

Luis Felipe de Deus

**ESTIMATIVA DA PRESSÃO ARTERIAL ATRAVÉS DE MODELOS DE INTELIGÊNCIA
ARTIFICIAL NO PROCESSAMENTO DE SINAIS DE FOTOPLETISMOGRAFIA**

Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Engenharia de Computação, da Universidade Federal de Santa Maria (UFSM, RS), como requisito parcial para obtenção do grau de **Engenheiro de Computação**.

Aprovado em 16 de setembro de 2020:

Cesar Augusto Prior, Dr. (UFSM)
(Presidente/Orientador)

Cesar Ramos Rodrigues, Dr. (UFSC)

Carlos Henrique Barriquello, Dr. (UFSM)

Santa Maria, RS
2020

AGRADECIMENTOS

A realização deste trabalho representa a conclusão da etapa de graduação, a qual demandou muito esforço, dedicação e força para nunca desistir, bem como o auxílio e compreensão de diversas pessoas. De maneira especial agradeço:

- Aos meus pais Daniel e Roselei, por tudo aquilo que sou hoje, pelas oportunidades, amor, carinho e compreensão, pelo suporte e pela chance de alcançar meus sonhos.*
- À Universidade Federal de Santa Maria, em especial ao Centro de Tecnologia, que dispôs infraestrutura e corpo docente capacitado a oferecer educação de qualidade durante meu período de graduação.*
- À empresa Vastmindz, London UK, em especial ao seu CEO, Nikhil Sehgal pela fantástica oportunidade que me foi concedida.*
- À todos os Professores e servidores que diariamente contribuíram para a minha formação.*
- Aos meus amigos e colegas ao longo da graduação pela amizade e colaboração, em especial aos meus amigos Nathanael Luchetta e Tiago Knorst, pela amizade, por todas as conversas, pelas noites que passamos em claro fazendo trabalhos e projetos juntos, pelo apoio e por servirem de inspiração, pois sempre tentava ter notas como as de vocês, e quando trabalhávamos juntos, tinha a certeza de que não havia projeto que não fôssemos capazes de fazer.*
- Aos amigos com quem dividi apartamento, em especial ao Samuel de Deus e ao Yuri Oliveira, pela parceria, risadas e conversas.*
- Um agradecimento especial para aqueles que eu perdi este ano, a minha avó dona Laureci, que nos deixou recentemente, por todo amor, carinho, ensinamentos e cuidado durante toda a minha vida, obrigado por tudo. A um dos melhores amigos que tive a honra de ter, meu amigo Nathanael, que nos deixou no início do ano de 2020, talvez a pessoa com quem mais passei tempo nestes 5 anos, mais do que com minha família, obrigado por tudo, você sempre foi uma inspiração por ser um gênio, mas mais do que tudo pelo teu caráter.*

RESUMO

ESTIMATIVA DA PRESSÃO ARTERIAL ATRAVÉS DE MODELOS DE INTELIGÊNCIA ARTIFICIAL NO PROCESSAMENTO DE SINAIS DE FOTOPLETISMOGRAFIA

AUTOR: Luis Felipe de Deus

ORIENTADOR: Cesar Augusto Prior

A medida da pressão arterial, e possíveis alterações da normalidade desta, está associada a várias comorbidades como em doenças cardiovasculares, cardiorrespiratórias entre outras. Dados reportados pelo *Institute for Health Metrics and Evaluation* (IHME) demonstram que doenças cardiovasculares são o principal fator de mortes ao redor do mundo, matando 17.8 milhões de pessoas no ano de 2017, juntamente com 3.91 milhões de mortes por doenças respiratórias. A pressão arterial é aferida em dois valores, a Pressão Arterial Sistólica (SBP), referente ao movimento de contração do coração, a sístole, onde a pressão é maior, e a Pressão Arterial Diastólica (DBP), referente ao movimento de relaxamento do coração, diástole, onde a pressão é menor. No presente momento os métodos mais utilizados para a aferição da pressão arterial não podem ser utilizados ininterruptamente, como o Esfigmomanômetro, que contrai, geralmente a artéria braquial, a uma pressão maior do que a pressão do indivíduo, outros métodos são invasivos, onde é introduzido um cateter na artéria do paciente, o que pode gerar desconforto e possíveis infecções.

Este trabalho propõe um estudo de técnicas para a aferição contínua e não invasiva da pressão arterial, através do processamento de sinais de Fotopletismografia em conjunto com algoritmos de Inteligência Artificial. A pesquisa foi executada em duas bases de dados diferentes, sendo uma da Universidade de Queensland, e a outra da Universidade Federal de Santa Maria (UFSM). Foram desenvolvidas três metodologias diferentes, denominadas *Single PPG Wave*, *Sliding Window* e *Scalogram*, para cada método foi elaborado um conjunto de experimentos com o propósito de corroborar para com os resultados apresentados, bem como uma análise de cada teste. As abordagens utilizadas foram no âmbito da regressão, que estima um valor de ponto flutuante, e na classificação, que busca situar a condição do paciente em uma classe. Em termos de performance este trabalho atingiu os padrões AAMI onde o dispositivo deve ter erro médio menor do que 5 mmHg e desvio padrão menor do que 8 mmHg, e a classe A no padrão da Sociedade Britânica de Hipertensão. Os melhores resultados demonstram que o método *Sliding Window* com o algoritmo *Random Forest* atingiu erro médio e desvio padrão de 0.94 ± 2.31 mmHg para a aferição da SBP e 0.60 ± 1.39 mmHg para DBP, dentre um total de 55.493 predições.

Palavras-chave: Pressão Arterial. Fotopletismografia. Inteligência Artificial

ABSTRACT

BLOOD PRESSURE ESTIMATION USING ARTIFICIAL INTELLIGENCE MODELS IN PHOTOPLETHYSMOGRAPHY SIGNAL PROCESSING

AUTHOR: Luis Felipe de Deus

ADVISOR: Cesar Augusto Prior

Blood pressure measurement, and possible changes in the normality of this, it is associated with several comorbidities such as cardiovascular and cardiorespiratory diseases among others. Data reported by the Institute for Health Metrics and Evaluation (IHME) show that cardiovascular diseases are the main cause of death worldwide, killing 17.8 million people in 2017, along with 3.91 million deaths from respiratory diseases. Blood pressure is measured in two values, Systolic Blood Pressure (SBP), referring to the contraction movement of the heart, systole, where the pressure is higher, and Diastolic Blood Pressure (DBP), referring to the relaxation movement of the heart, diastole, where the pressure is less. At the present moment, the most used methods for measuring blood pressure cannot be used continuously, such as the sphygmomanometer, which contracts, usually the brachial artery, at a higher pressure than the individual's pressure, other methods are invasive, where a catheter is required in the patient's artery, which can cause discomfort and possible infections to the patient.

This work proposes a study of techniques for the continuous and non-invasive measurement of blood pressure, through the processing of Photoplethysmography signals in conjunction with Artificial Intelligence algorithms. The research was carried out in two different datasets, one from Queensland University and the other from Federal University of Santa Maria (UFSM). Three different methodologies were developed, called Single PPG Wave, Sliding Window and Scalogram, for each method, a set of experiments was designed with the purpose of corroborating the results presented, as well as an analysis of each test. The approaches used were in the scope of regression, which estimates a floating point value, and in the classification, which seeks to situate the patient's condition in a class. In terms of performance, this work reached the AAMI standards where the device must have an average error of less than 5 mmHg and standard deviation of less than 8 mmHg, as well as class A in the British Hypertension Society standard. The best results show that the Sliding Window method with the Random Forest algorithm reached average error and standard deviation of 0.94 ± 2.31 mmHg for SBP measurement and 0.60 ± 1.39 mmHg for DBP, among a total of 55,493 predictions.

Keywords: Blood Pressure. Photoplethysmography. Artificial Intelligence

LISTA DE FIGURAS

Figura 1.1 – Movimentos de Sístole e Diástole do coração.	13
Figura 1.2 – Número de mortes por causa globalmente em 2017.	15
Figura 2.1 – Extração de sinais simultâneos, Pressão Sanguínea Arterial (ABP) invasiva, Fotopletismografia (PPG) não invasiva.	18
Figura 2.2 – Esquemático para aquisição do sinal de PPG por meio de transmissão e reflexão à esquerda; representação da variação da luz através dos tecidos do corpo humano à direita.	18
Figura 2.3 – Exemplo de resposta em frequência para os filtros: a) Butterworth b) Chebyshev I c) Elíptico.	20
Figura 2.4 – Exemplo de representação no tempo e por meio de um <i>Scalogram</i>	21
Figura 2.5 – Exemplo do algoritmo <i>Decision Tree</i>	23
Figura 2.6 – Exemplo do algoritmo <i>Random Forest</i>	24
Figura 2.7 – Exemplo de uma arquitetura de Rede Neural Convolucional.	25
Figura 2.8 – Rede Neural Convolucional - Arquitetura proposta por Wang.	26
Figura 2.9 – Arquitetura do módulo Inception.	27
Figura 2.10 – Exemplo de Matriz de Confusão.	29
Figura 4.1 – Exemplo de extração de <i>features</i> de caráter morfológico.	35
Figura 4.2 – Extração de <i>features</i> usando a abordagem <i>Single PPG Wave</i>	35
Figura 4.3 – Exemplo de execução da abordagem <i>Sliding Window</i> através do sinal de PPG.	36
Figura 4.4 – Exemplos de imagens <i>Scalogram</i> obtidos de duas janelas de sinais de PPG distintas.	38
Figura 4.5 – Fluxograma do protocolo utilizado para coleta de dados no <i>dataset</i> da UFSM.	40
Figura 4.6 – Exemplo de sinal de PPG com marcações para estágios do experimento e referências da aferição da pressão arterial.	41
Figura 4.7 – Fluxograma de execução do trabalho proposto.	42
Figura 4.8 – Exemplo de pré-processamento em um sinal de PPG limpo do <i>dataset</i> de Queensland - Paciente 29.	43
Figura 4.9 – Exemplo de pré-processamento em um sinal de PPG ruidoso do <i>dataset</i> de Queensland - Paciente 01.	43
Figura 4.10 – Exemplo de <i>data frame</i> - <i>samples x features</i>	44
Figura 5.1 – Histograma da diversidade de referências para SBP e DBP no <i>dataset</i> de Queensland.	49
Figura 5.2 – Gráfico de Bland-Altman para SBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Decision Tree</i> e o <i>dataset</i> de Queensland.	49
Figura 5.3 – Gráfico de Bland-Altman para DBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Decision Tree</i> e o <i>dataset</i> de Queensland.	49
Figura 5.4 – Gráfico de Bland-Altman para SBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Random Forest</i> e o <i>dataset</i> de Queensland.	51
Figura 5.5 – Gráfico de Bland-Altman para DBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Random Forest</i> e o <i>dataset</i> de Que-	

ensland.	51
Figura 5.6 – Gráfico da distribuição das classes no <i>dataset</i> de Queensland segundo as diretrizes brasileiras para classificação de pressão arterial.	54
Figura 5.7 – Gráfico da distribuição das classes no <i>dataset</i> de Queensland segundo as diretrizes da JNC7 para classificação de pressão arterial.	54
Figura 5.8 – Histograma da diversidade de referências para SBP e DBP no <i>dataset</i> da UFSM.	58
Figura 5.9 – Gráfico de Bland-Altman para SBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Decision Tree</i> e o <i>dataset</i> da UFSM.	59
Figura 5.10 – Gráfico de Bland-Altman para DBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Decision Tree</i> e o <i>dataset</i> da UFSM.	59
Figura 5.11 – Gráfico de Bland-Altman para SBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Random Forest</i> e o <i>dataset</i> da UFSM.	60
Figura 5.12 – Gráfico de Bland-Altman para DBP na abordagem <i>Sliding Window</i> com janela de 100s usando o algoritmo <i>Random Forest</i> e o <i>dataset</i> da UFSM.	61
Figura 5.13 – Gráfico da distribuição das classes no <i>dataset</i> da UFSM segundo as diretrizes brasileiras para classificação da pressão arterial.	62
Figura 5.14 – Gráfico da distribuição das classes no <i>dataset</i> da UFSM segundo as diretrizes da JNC7 para classificação da pressão arterial.	63
Figura 5.15 – Curva de aprendizado usando CNN para o <i>dataset</i> de Queensland. ...	66
Figura 5.16 – Curva de aprendizado usando GoogLeNet para o <i>dataset</i> de Queensland.	66
Figura 5.17 – Curva de aprendizado usando CNN para o <i>dataset</i> da UFSM.	68
Figura 5.18 – Curva de aprendizado usando GoogLeNet para o <i>dataset</i> da UFSM. ..	68

LISTA DE TABELAS

Tabela 2.1 – <i>British Hypertension Society</i> critério.	29
Tabela 3.1 – Resultados de outros autores usando a abordagem de regressão.	33
Tabela 3.2 – Resultados de outros autores usando a abordagem de classificação.	33
Tabela 4.1 – Dados coletados para cada paciente do <i>dataset</i> de Queensland.	39
Tabela 5.1 – Resultados usando base de dados de Queensland para diferentes algoritmos de AI na abordagem <i>Single PPG Wave</i>	45
Tabela 5.2 – Resultados usando base de dados da UFSM para diferentes algoritmos de AI na abordagem <i>Single PPG Wave</i>	46
Tabela 5.3 – Resultados usando o <i>dataset</i> de Queensland para diferentes tamanhos de janelas na abordagem <i>Sliding Window</i> usando algoritmo <i>Decision Tree</i>	47
Tabela 5.4 – Resultados usando métricas BHS para o <i>dataset</i> de Queensland usando a abordagem <i>Sliding Window</i> - SBP.	48
Tabela 5.5 – Resultados usando métricas BHS para o <i>dataset</i> de Queensland usando a abordagem <i>Sliding Window</i> - DBP.	48
Tabela 5.6 – Resultados <i>Random Forest</i> com janela de 100s usando o <i>dataset</i> de Queensland.	50
Tabela 5.7 – Resultados usando <i>K-Fold Cross Validation</i> com janela de 100s, algoritmo <i>Decision Tree</i> e o <i>dataset</i> de Queensland.	52
Tabela 5.8 – Classificação de pressão arterial para indivíduos maiores de 18 anos segundo diretrizes brasileiras.	53
Tabela 5.9 – Classificação de pressão arterial para indivíduos maiores de 18 anos segundo diretrizes da JNC7.	53
Tabela 5.10 – Matriz de confusão usando diretrizes brasileiras para o <i>dataset</i> de Queensland.	55
Tabela 5.11 – Resultados usando diretrizes brasileiras para o <i>dataset</i> de Queensland.	55
Tabela 5.12 – Matriz de confusão usando diretrizes da JNC7 para o <i>dataset</i> de Queensland.	55
Tabela 5.13 – Resultados usando diretrizes da JNC7 para o <i>dataset</i> de Queensland.	56
Tabela 5.14 – Resultados usando base de dados da UFSM para diferentes tamanhos de janelas na abordagem <i>Sliding Window</i> usando algoritmo <i>Decision Tree</i>	56
Tabela 5.15 – Resultados usando métricas BHS para a base de dados da UFSM usando a abordagem <i>Sliding Window</i> - SBP.	57
Tabela 5.16 – Resultados usando métricas BHS para a base de dados da UFSM usando a abordagem <i>Sliding Window</i> - DBP.	57
Tabela 5.17 – Resultados <i>Random Forest</i> com janela de 100s para o <i>dataset</i> da UFSM.	60
Tabela 5.18 – Resultados usando <i>K-Fold Cross Validation</i> com janela de 100s, algoritmo <i>Decision Tree</i> e o <i>dataset</i> da UFSM.	61
Tabela 5.19 – Matriz de confusão usando diretrizes brasileiras para o <i>dataset</i> da UFSM.	63
Tabela 5.20 – Resultados usando diretrizes brasileiras para o <i>dataset</i> da UFSM.	64
Tabela 5.21 – Matriz de confusão usando diretrizes da JNC7 para o <i>dataset</i> da UFSM.	64
Tabela 5.22 – Resultados usando diretrizes da JNC7 para o <i>dataset</i> da UFSM.	64
Tabela 5.23 – Resultados usando redes neurais para o <i>dataset</i> de Queensland.	67

Tabela 5.24 – Resultados usando redes neurais para o <i>dataset</i> da UFSM.....	68
Tabela 5.25 – Comparação de resultados do presente trabalho no âmbito da regressão para o <i>dataset</i> de Queensland.....	70
Tabela 5.26 – Comparação de resultados do presente trabalho no âmbito da classificação para o <i>dataset</i> de Queensland.....	71
Tabela 5.27 – Comparação de resultados do presente trabalho com o de outros autores usando regressão.....	72
Tabela 5.28 – Comparação de resultados do presente trabalho com o de outros autores usando classificação.....	73
Tabela C.1 – Lista de <i>features</i> para a abordagem <i>Single PPG Wave</i>	80

LISTA DE ABREVIATURAS E SIGLAS

<i>AAMI</i>	American Association for the Advancement of Medical Instrumentation
<i>ABP</i>	Arterial Blood Pressure
<i>AI</i>	Artificial Intelligence
<i>APG</i>	Acceleration Plethysmogram
<i>BHS</i>	British Hypertension Society
<i>BP</i>	Blood Pressure
<i>CNN</i>	Convolution Neural Networks
<i>COPD</i>	Chronic Obstructive Pulmonary Disease
<i>CVD</i>	Cardiovascular Disease
<i>CWT</i>	Continuous Wavelet Transform
<i>DBP</i>	Diastolic Blood Pressure
<i>DT</i>	Decision Tree
<i>ECG</i>	Electrocardiogram
<i>IHME</i>	Institute for Health Metrics and Evaluation
<i>JNC7</i>	Seventh Report of the Joint National Committee
<i>ME</i>	Mean Error
<i>PPG</i>	Photoplethysmography
<i>PTT</i>	Pulse Transit Time
<i>RF</i>	Random Forest
<i>SBP</i>	Systolic Blood Pressure
<i>SD</i>	Standard Deviation
<i>SVM</i>	Support Vector Machine
<i>VPG</i>	Velocity Plethysmogram
<i>WHO</i>	World Health Organization

SUMÁRIO

1	INTRODUÇÃO	13
1.1	OBJETIVOS	14
1.2	JUSTIFICATIVA	14
1.3	ORGANIZAÇÃO DOS CAPÍTULOS	16
2	REVISÃO TEÓRICA	17
2.1	FOTOPLETISMOGRAFIA	17
2.2	PROCESSAMENTO DE SINAIS	18
2.2.1	Savitzky-Golay	19
2.2.2	Butterworth	19
2.2.3	Transformada Contínua de Wavelet	20
2.2.4	Normalização Min Max	22
2.3	INTELIGÊNCIA ARTIFICIAL	22
2.3.1	Python	22
2.3.2	Machine Learning	22
2.3.2.1	Decision Tree	23
2.3.2.2	Random Forest	23
2.3.3	Deep Learning	24
2.3.3.1	Convolution Neural Networks	24
2.3.3.2	GoogLeNet	27
2.4	ADASYN	28
2.5	MÉTRICAS DE AVALIAÇÃO	28
2.5.1	Métricas para Regressão	28
2.5.2	Métricas para Classificação	29
3	TRABALHOS RELACIONADOS	31
4	METODOLOGIA	34
4.1	SINGLE PPG WAVE	34
4.2	SLIDING WINDOW	36
4.3	SCALOGRAM	37
4.4	DATASETS	38
4.4.1	Queensland dataset	39
4.4.2	UFSM dataset	40
4.5	AMBIENTE DE DESENVOLVIMENTO	41
4.6	MÉTODO	42
5	RESULTADOS	45
5.1	RESULTADOS DA ABORDAGEM SINGLE PPG WAVE	45
5.1.1	Queensland dataset	45
5.1.2	UFSM dataset	46
5.2	RESULTADOS DA ABORDAGEM SLIDING WINDOW	47
5.2.1	Queensland dataset	47
5.2.1.1	Análise de overfitting	50
5.2.1.2	Análise do algoritmo	50
5.2.1.3	Validação cruzada	51
5.2.1.4	Classificação	52
5.2.2	UFSM dataset	56
5.2.2.1	Análise de overfitting	59


5.2.2.2	<i>Análise do algoritmo</i>	60
5.2.2.3	<i>Validação cruzada</i>	61
5.2.2.4	<i>Classificação</i>	62
5.3	RESULTADOS DA ABORDAGEM <i>SCALOGRAM</i>	65
5.3.1	Queensland <i>dataset</i>	65
5.3.2	UFSM <i>dataset</i>	67
5.4	COMPARAÇÃO DE RESULTADOS DESTE TRABALHO.....	69
5.5	COMPARAÇÃO DE RESULTADOS COM DIFERENTES AUTORES	71
6	CONCLUSÃO	74
	REFERÊNCIAS BIBLIOGRÁFICAS	75
	APÊNDICE A – ARQUITETURA GOOGLNET	78
	APÊNDICE B – ESTRUTURA DE DIRETÓRIOS DO <i>DATASET</i> DA UFSM	79
	APÊNDICE C – <i>FEATURES</i> DA ABORDAGEM <i>SINGLE PPG WAVE</i>	80

1 INTRODUÇÃO

A pressão arterial (BP, do inglês), fora dos padrões de normalidade, é um dos principais indicadores em doenças cardiovasculares (CVD, do inglês), um índice anormal de pressão pode causar derrames, ataques cardíacos e insuficiência renal (HöCHT, 2013). O coração, órgão do sistema cardiovascular responsável por bombear o sangue através dos vasos sanguíneos para todo o corpo, possui dois tipos de movimentos: sístole e diástole. A Fig.1.1 exemplifica tais movimentos em uma visão do coração humano. A sístole é o movimento de contração em que o sangue é bombeado para o corpo. A diástole é o movimento de relaxamento, quando o coração se enche de sangue (GUYTON; HALL, 2011).

Pressão arterial é um sinal periódico com a frequência cardíaca do coração, refere-se à pressão exercida pelo sangue contra a parede das artérias. O limite superior da pressão arterial é chamado Pressão Arterial Sistólica (SBP, do inglês), onde a pressão exercida é maior, enquanto seu limite inferior é chamado Pressão Arterial Diastólica (DBP, do inglês), onde a pressão exercida é menor (KACHUEE et al., 2015). A unidade de medida padrão é o mmHg (milímetros de mercúrio).

Figura 1.1 – Movimentos de Sístole e Diástole do coração.



Fonte: (Janet Ungless, 2020).

A maneira mais precisa e comum para medir a pressão arterial, atualmente é através do aparelho chamado Esfigmomanômetro (KACHUEE et al., 2015), que consiste em um sistema para compressão da artéria braquial onde deve-se inflar ao redor do braço para que a pressão arterial possa ser medida com o auxílio de um estetoscópio para a ausculta dos sons de Korotkov sendo assim possível a verificação tanto da pressão sistólica quanto da pressão diastólica (KUMAR; AYUB, 2015). Entretanto, este procedimento não pode ser contínuo, visto que interrompe a circulação sanguínea inflando o aparelho a uma pressão maior do que a pressão arterial do paciente.

Para pacientes acamados, algumas vezes, faz-se necessário o monitoramento contínuo, entretanto o método utilizado é invasivo, a pressão arterial por este método é medida através de um cateter introduzido na artéria, o qual é conectado em uma coluna líquida, este procedimento é descrito como Padrão Ouro (*Gold Standard*) (SENTURK; YUCEDAG; POLAT, 2018). A medida da pressão é obtida através do transdutor de pressão que faz a leitura, são obtidas então, a forma de onda da Pressão Arterial (ABP, do inglês) e os valores da pressão sistólica, diastólica e média. Contudo, o procedimento pode ser inconveniente, desconfortável e oferecer potenciais riscos para pacientes, como infecção, sangramento no local e obstrução arterial (KUMAR; AYUB, 2015).

Nos últimos anos, vários grupos de pesquisadores vêm tentando desenvolver diversas técnicas para a medição ou estimativa contínua e não invasiva da pressão arterial, por meio do processamento de sinais biomédicos adquiridos por sensores e eletrodos. A principal ferramenta para estes estudos tem sido o uso do sinal da fotopletismografia (PPG, do inglês), como descrito no estudo de (MARTÍNEZ et al., 2018).

1.1 OBJETIVOS

Os objetivos gerais propostos por este trabalho são o estudo da viabilidade de modelos de inteligência artificial em aferir com uma taxa de acerto aceitável a pressão arterial de pessoas por meio do processamento de sinais biomédicos, bem como a descoberta de informações importantes provenientes da sua morfologia e de suas características.

O modelo sugerido, deve ser capaz de ser embarcado em uma aplicação *open source* com o mínimo de tamanho, preço e custo computacional possível. Que possa ser capaz de estimar a pressão arterial em diversas bases de dados com aquisições de sinais referentes a pessoas de diversas idades, sexo e condição clínica, tanto em repouso, quanto em movimento, para que o modelo seja seguro ao público em geral. Tal sistema estaria inserido no conceito de Saúde 4.0 abordado por (SANTOS et al., 2018).

1.2 JUSTIFICATIVA

Informações publicadas no site (Our World in Data, 2020), especializado em dados estatísticos, mostraram que em 2017, 56 milhões de pessoas morreram no mundo, entretanto, com os dados reportados pelo *Institute for Health Metrics and Evaluation* (IHME), somente doenças cardiovasculares mataram aproximadamente 17.8 milhões de pessoas, 8 milhões a mais do que o Câncer, que ocupa a segunda posição. A Fig.1.2 demonstra o número de mortes por causa, no ano de 2017.


Segundo a *World Health Organization* (WHO), em 2014 as estatísticas mundiais relataram que a hipertensão causa 9.4 milhões de mortes por ano, em 2015 dados mostraram que 1 em cada 4 homens e 1 em cada 5 mulheres tem hipertensão, chegando a uma estimativa de 2019 em que 1.13 bilhão de pessoas ao redor do mundo possuem tal condição (World Health Organization, 2020). Fazendo com que a doença fosse reconhecida como o segundo maior fator de doença cardiovascular após o diabetes. Sendo chamada de “assassino silencioso”, devido ao fato de seus portadores não saberem da hipertensão e a maneira de controlá-la (KACHUEE et al., 2015).

Um dos problemas que pessoas com hipertensão enfrentam é o fato da pressão arterial variar durante o dia por vários fatores, como ingestão de alimentos, situações mentais ou estresse (KACHUEE et al., 2015). Segundo o estudo de (CHOBANIAN et al., 2003) para indivíduos entre 40 e 70 anos de idade, cada incremento de 20 mmHg na pressão arterial sistólica ou 10 mmHg na pressão arterial diastólica, dobra o risco do paciente ter uma doença cardiovascular.

Portanto, seria de grande relevância para a sociedade o monitoramento contínuo e não invasivo da pressão arterial, entretanto, para isso faz-se necessária uma solução que possa ser embarcada, para não somente pacientes acamados, como também pessoas normais em seu uso cotidiano.

A justificativa para este trabalho é a proposta de criação de um método capaz de estimar a pressão arterial de forma contínua, não invasiva e com uma taxa de acerto dentro dos padrões para dispositivos não invasivos neste âmbito, e que preze pela otimização de custo computacional.

Figura 1.2 – Número de mortes por causa globalmente em 2017.



Fonte: (Our World in Data, 2020).

1.3 ORGANIZAÇÃO DOS CAPÍTULOS

A composição deste trabalho se apresenta em 6 capítulos. O capítulo 2 apresenta uma breve revisão teórica, com o objetivo de esclarecer ao leitor os conceitos explorados neste trabalho, tanto da parte de sinais biomédicos, que é a área de aplicação, bem como conceitos sobre processamento digital de sinais e inteligência artificial que compõem a área deste trabalho.

O capítulo 3 apresenta ao leitor uma revisão dos trabalhos relacionados a este estudo. Os trabalhos previamente selecionados, buscam manter uma similaridade em termos de base de dados utilizadas, para que seja possível apresentar comparações plausíveis para com os resultados obtidos através das diferentes abordagens, deste trabalho, com as abordagens de outros autores.

O capítulo 4 apresenta a metodologia seguida neste trabalho, detalhando as diferentes abordagens criadas neste estudo, e seus métodos, bem como uma breve descrição das bases de dados utilizadas e como é sua disposição. O capítulo 5, por sua vez, apresenta os resultados obtidos neste trabalho, individualmente para cada abordagem criada, bem como uma comparação de resultados obtidos, primeiramente entre as diferentes abordagens deste trabalho, e posteriormente os melhores resultados foram selecionados para efetuar uma comparação com resultados de outros autores.

O capítulo 6 conclui o trabalho revisando brevemente os objetivos propostos em contraste aos resultados obtidos, além de traçar possíveis trabalhos futuros na temática abordada.

2 REVISÃO TEÓRICA

Este capítulo tem por objetivo elucidar os principais conceitos tratados neste trabalho. Serão abordados os conceitos da fotopletismografia, buscando uma breve explanação sobre o assunto, bem como as diferentes técnicas de processamento de sinais utilizadas neste trabalho, como filtragem de sinais e preparação de dados. Por fim, uma breve contextualização sobre inteligência artificial e os protocolos para avaliar a performance dos métodos propostos.


2.1 FOTOPLETISMOGRAFIA

Fotopletismografia (PPG, do inglês), ou Pletismografia fotoeletrônica, é um método não invasivo usado para extrair sinais fisiológicos do sistema cardiovascular humano (EL-GENDI et al., 2018), baseado na iluminação de uma área, normalmente a ponta do dedo, ou o pulso, onde é refletida a variação do fluxo sanguíneo entre as fases sistólicas e diastólicas do ciclo cardíaco do paciente (SANTANA, 2017).

O sinal de PPG e ABP tem a mesma fonte de excitação, o coração, então pode ser esperada uma similaridade dos sinais, tanto no domínio do tempo, quanto na frequência, e por consequência uma correlação (MARTÍNEZ et al., 2018). De acordo com o autor, em suas conclusões, ressalta que técnicas baseadas no sinal do PPG são muito promissoras para estimar a pressão arterial, sendo um potencial substituto para técnicas invasivas de ABP. A Fig.2.1 demonstra ambos os sinais.

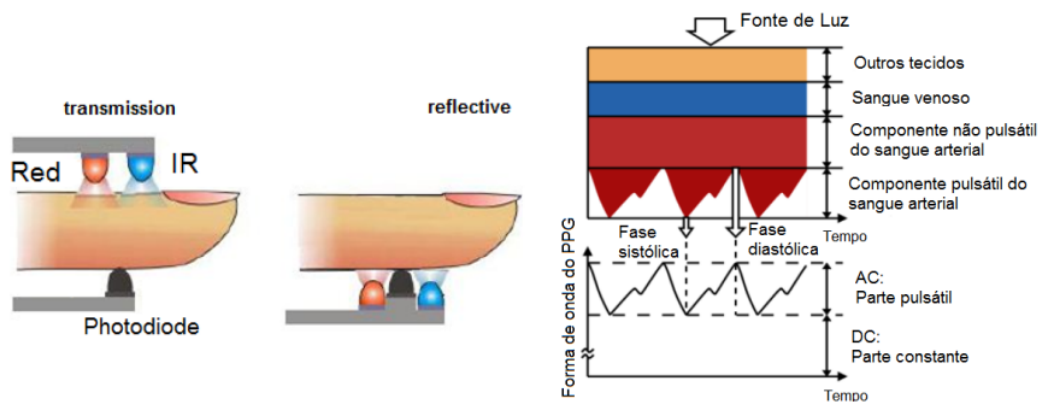
O PPG produz um sinal óptico relacionado a pulsações volumétricas arteriais e tem amplo potencial em aplicações clínicas devido à sua simplicidade, por ser um método não invasivo e seu baixo custo monetário. O sinal é obtido iluminando a região de interesse do corpo (KAVSAOGLU; POLAT; BOZKURT, 2016). A construção desse sistema pode ser através de um Diodo Emissor de Luz (LED, do inglês), como demonstra a Fig.2.2, onde se tem um transmissor na parte de cima e um fotodiodo receptor na parte de baixo, do dedo por exemplo, ou através do princípio da reflexão, onde ambos estão no mesmo lado.

Figura 2.1 – Extração de sinais simultâneos, Pressão Sanguínea Arterial (ABP) invasiva, Fotopletismografia (PPG) não invasiva.



Fonte: (MARTÍNEZ et al., 2018).

Figura 2.2 – Esquemático para aquisição do sinal de PPG por meio de transmissão e reflexão à esquerda; representação da variação da luz através dos tecidos do corpo humano à direita.



Fonte: Adaptado de (KHALID et al., 2018) e (TAMURA et al., 2014).

2.2 PROCESSAMENTO DE SINAIS

Sinais de PPG são extraídos sobre um processo envolvendo luz, seja ela direta ou indireta ao corpo humano, entretanto, variáveis como taxa de gordura corporal, coloração da pele, incidência de luz externa, respiração, entre outros, podem tornar o sinal de PPG com grandes proporções de ruídos, sendo inviável a utilização do sinal na sua forma original (*raw*). Todavia, faz-se necessário um estágio de pré-processamento, onde serão empregadas técnicas de processamento de sinais, após este estágio o sinal estará habilitado a ser processado.

De acordo com um estudo realizado por (ELGENDI et al., 2018), onde foram avaliados diferentes tipos de filtros e sua performance sobre sinais de PPG. A avaliação contou com nove (9) tipos de filtros com dez (10) diferentes ordens para cada um, resultando em 90 diferentes configurações. Os autores concluíram então, que o filtro Chebyshev II seguido pelo filtro Butterworth, ambos de 4ª ordem, obtiveram a melhor performance, baseado no indicador SQI (*Signal Quality Index*).

Entretanto nos testes realizados neste trabalho, constatou-se que a técnica que obteve o melhor desempenho na redução de ruídos dos sinais de PPG foi uma combinação dos filtros Savitzky-Golay e Butterworth. Portanto este foi o método usado no pré-processamento dos sinais neste estudo. A configuração utilizada no filtro Savitzky-Golay foi de 19 *frames* e 4ª ordem, enquanto no filtro Butterworth foi de 2ª ordem com frequência de corte entre 0.5 Hz e 6 Hz.

2.2.1 Savitzky-Golay

Proposto por Abraham Savitzky e Marcel Golay, o filtro Savitzky-Golay é um tipo de filtro digital que pode ser aplicado a um conjunto de dados (pontos) com o objetivo de suavizar os dados, ou seja, aumentar a precisão dos dados sem distorcer a tendência (SAVITZKY; GOLAY, 1964).

Como descrito por Schafer (Schafer, 2011), o filtro é baseado na aproximação polinomial dos mínimos quadrados. A base do estudo mostra que ajustar um polinômio a um conjunto de amostras de entrada e depois avaliar o polinômio resultante em um único ponto dentro do intervalo de aproximação é equivalente a uma convolução discreta com uma resposta de impulso fixa.

2.2.2 Butterworth

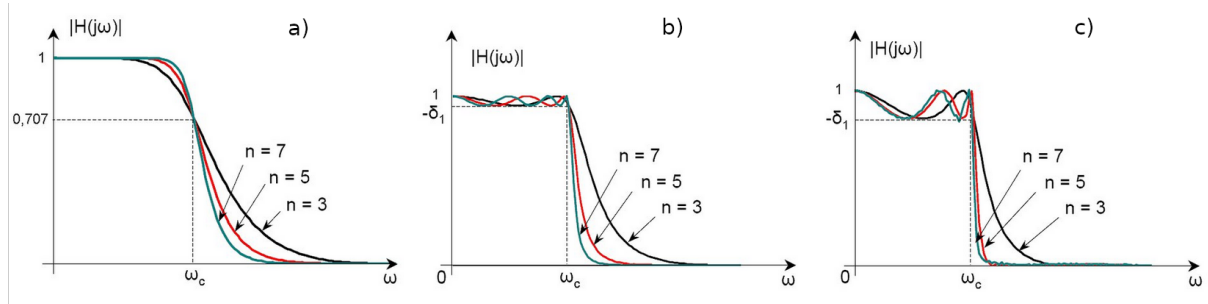
O filtro do tipo Butterworth é amplamente utilizado na área de eletrônica e processamento digital de sinais, devido suas características de frequência e fase. Proposto inicialmente pelo engenheiro britânico Stephen Butterworth, foi desenvolvido com o objetivo de ter uma resposta em frequência o mais plana o quanto for matematicamente possível na banda passante.

A resposta em frequência do filtro passa-baixas Butterworth é uma função da sua ordem “n” e da frequência de corte ω_c , descrito na equação 2.1 (MIHAI; MIHAI, 2015). A Fig.2.3 por sua vez, demonstra uma comparação da resposta em frequência em três diferentes ordens para os filtros digitais Butterworth, Chebyshev I e Elíptico, semelhantes

e amplamente usados nesta categoria.

$$|H(j\omega)| = \frac{1}{\sqrt{1 + \left(\frac{\omega}{\omega_c}\right)^{2n}}} \quad (2.1)$$

Figura 2.3 – Exemplo de resposta em frequência para os filtros: a) Butterworth b) Chebyshev I c) Elíptico.



Fonte: Adaptado de (MIHAI; MIHAI, 2015).

2.2.3 Transformada Contínua de Wavelet

Nas últimas décadas, o processamento de imagens tem se reinventado, métodos de compressão de imagens utilizados na década de 80 e 90, hoje podem ser obsoletos, e uma das tecnologias responsáveis por isso, foi a utilização da transformada de Wavelet (DOMINGUES et al., 2016). De acordo com a literatura, a transformada por Wavelet, juntamente com a Transformada Discreta de Cosseno (DCT, do inglês) são hoje, as principais ferramentas utilizadas para compressão de imagens, segundo (DOMINGUES et al., 2016, p. 1–2) presentes em imagens no formato JPEG ou em animações 3D.

De acordo com (FOUFOULA-GEORGIU; KUMAR, 1994 apud DOMINGUES et al., 2016, p. 2): “A transformada Wavelet equivale a um microscópio matemático, cuja ampliação é dada pelo inverso do parâmetro de dilatação e a capacidade óptica pela escolha da função Wavelet-mother”.

A Transformada Contínua de Wavelet (CWT, do inglês), por sua vez, é uma função integral linear que é principalmente utilizada para explorar sinais não estacionários, onde há a variação de frequências. A CWT, pode ser definida como a soma ao longo do tempo de um sinal multiplicado por uma escala, e deslocado por uma função Wavelet (Psi), também chamada Wavelet-mother. A CWT é definida pela equação Eq.2.2, enquanto a equação Eq.2.3 mostra a definição geral da Wavelet-mother.

$$F(a, b) = \int f(t)\psi_{a,b}(t)dt \quad (2.2)$$

$$\psi_{a,b}(t) = \frac{1}{\sqrt{|a|}} \psi\left(\frac{t-b}{a}\right), a \neq 0, b \in \mathbb{R} \quad (2.3)$$

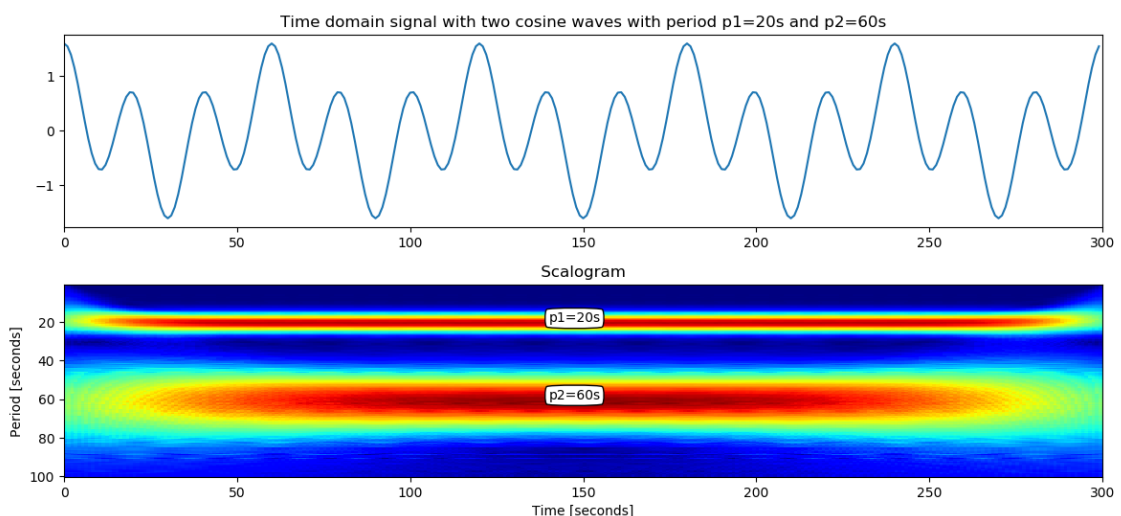
Há um vasto número de diferentes Wavelets, cada uma adequada para diferentes aplicações. Algumas das mais utilizadas são listadas abaixo.

- Wavelet de Haar,
- Wavelet de Meyer,
- Wavelet de Morse,
- Wavelet de Morlet,
- Wavelet Mexican Hat.

A CWT tem sido considerada um método eficiente para análise no domínio da frequência junto com o tempo. Os coeficientes resultantes da transformada de Wavelet, podem ser utilizados para construção de um gráfico, denominado *Scalogram*. Em linhas gerais, um *Scalogram* é um gráfico de tempo e frequência, formado pelos valores absolutos dos coeficientes resultantes da CWT aplicado em um sinal, a Fig.2.4 demonstra um exemplo usando um sinal composto de dois cossenos, respectivamente com períodos de 20 e 60 segundos.

O *Scalogram* pode ser comparado ao *Spectrogram* obtido através da Transformada Rápida de Fourier (FFT, do inglês), entretanto o gráfico obtido através da Wavelet pode identificar de uma melhor forma frequências baixas ou mudanças abruptas de frequência de acordo com (LIANG et al., 2018).

Figura 2.4 – Exemplo de representação no tempo e por meio de um *Scalogram*.



Fonte: Autor.

2.2.4 Normalização Min Max

A última etapa de pré-processamento empregada, é a normalização do sinal, esta técnica faz-se necessária, para evitar diferentes magnitudes em amplitude.

A amplitude do sinal de PPG, em sua maioria, é menor do que 1, sendo assim, foi utilizado a normalização “Min Max” que como o nome sugere, utiliza o valor mínimo e máximo de amplitude do sinal como parâmetros para a normalização, onde a equação é descrita pela Eq.2.4

$$PPGn[i] = \frac{PPGf[i] - \min(PPGf)}{\max(PPGf) - \min(PPGf)} \quad (2.4)$$

- **PPGn**: PPG normalizado
- **PPGf**: PPG filtrado

2.3 INTELIGÊNCIA ARTIFICIAL

Inteligência Artificial (AI, do inglês) é um ramo de estudo da computação que se propõe a estudar e a criar sistemas de computadores que exibem alguma forma de inteligência, sistemas que aprendem conceitos e tarefas, sistemas que podem raciocinar e tirar conclusões úteis sobre o mundo ao redor.

Nas últimas décadas, novos ramos da AI ganharam mais espaço, como o caso do *Machine Learning* e do *Deep Learning*, todavia, faz-se necessário o uso de linguagens de programação, para traduzir modelos computacionais para a linguagem de máquina.

2.3.1 Python

Python é uma linguagem de programação de propósito geral (multiparadigma), alto nível, interpretada e fracamente tipada, publicada em 1991 por Guido van Rossum. Python pode ser usada para aplicações web, jogos, e recentemente se tornou a principal ferramenta para *Machine Learning* e *Deep Learning*, que é o motivo para este trabalho ter usado esta linguagem.

2.3.2 Machine Learning

Enquanto a inteligência artificial pode ser definida, de modo amplo, como a ciência capaz de mimetizar as habilidades humanas, o *Machine Learning* é uma vertente especí-

fica da AI que treina máquinas para aprender com dados. Na atualidade, não há recurso maior em abundância do que dados estruturados e não estruturados. Na segunda metade do século 20, o *Machine Learning* evoluiu como uma sub-área da AI com algoritmos de auto aprendizagem que derivam conhecimento a partir de dados para fazer previsões futuras (RASCHKA; MIRJALILI, 2019).


Em vez de programadores manualmente construírem rotinas, o *Machine Learning* oferece uma alternativa mais eficiente para adquirir conhecimento a partir de dados, para gradualmente melhorar a performance das previsões.

2.3.2.1 Decision Tree

O algoritmo de Árvore de Decisão ou *Decision Tree* (DT) é uma técnica de aprendizado de máquina da categoria supervisionado, onde existe uma saída alvo ou *target* (Deep AI, 2020). Este algoritmo pode ser empregado tanto em problemas de classificação onde a saída alvo é um rótulo ou para problemas de regressão onde a saída alvo é um número.

O processo de treinamento se dá na construção da árvore, seguindo o conceito de árvores binárias vindo de estrutura de dados, onde cada nó interno (não folha) é um teste de atributo, cada ramificação é o resultado do teste, e cada nó folha contém um rótulo da classe (Deep AI, 2020). A Fig.2.5 demonstra um breve exemplo da construção de uma árvore de decisão.

Figura 2.5 – Exemplo do algoritmo *Decision Tree*.



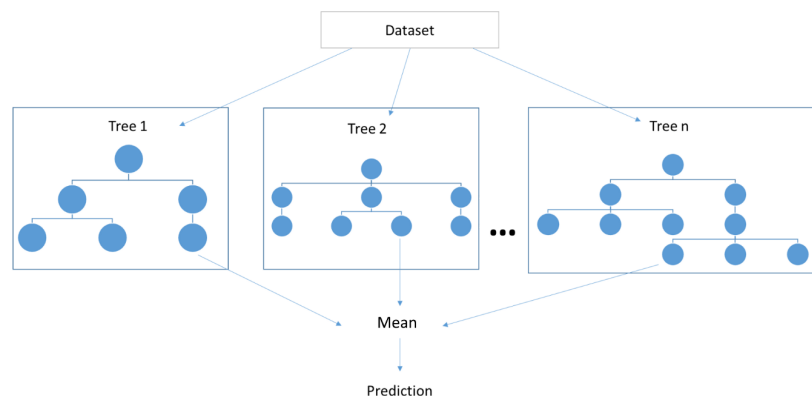
Fonte: (Deep AI, 2020).

2.3.2.2 Random Forest

Semelhante ao algoritmo *Decision Tree*, a técnica *Random Forest* aposta não na criação de uma única árvore para criar o modelo, e sim na criação de várias árvores, formando uma "floresta".

O objetivo não é criar um único modelo de aprendizado, e sim múltiplos modelos onde a saída final, será um função de todas as saídas intermediárias de cada árvore (Deep AI, 2020). O algoritmo ainda conta com a opção de setar o número de árvores, tipicamente entre 100 e 1.000 árvores, bem como a separação dos atributos usados em cada árvore é randômica o que reduz a probabilidade de *overfitting*, a Fig.2.6 exemplifica a dinâmica do algoritmo.

Figura 2.6 – Exemplo do algoritmo *Random Forest*.



Fonte: (Deep AI, 2020).

2.3.3 Deep Learning

Deep Learning pode ser considerado na categoria de *Machine Learning*, a principal diferença é que o paradigma de *Deep Learning* é voltado para redes neurais artificiais, as quais tentam imitar o cérebro humano, mais precisamente o modelo de um neurônio biológico.

Recentemente o *Deep Learning* tem atingido grande sucesso, e vem sendo frequentemente utilizado em visão computacional, para reconhecimento de voz, e reconhecimento de imagem. Na prática, *Deep Learning*, também conhecido como *Deep Structed Learning*, usa uma grande quantidade de *hidden layers* para extrair *features* dos dados e transformar em diferentes níveis de abstração (Deep AI, 2020).

2.3.3.1 Convolution Neural Networks

Redes Neurais Convolucionais (CNN, do inglês), ou ConvNet, é conhecida por ter uma arquitetura descrita como profunda e por uma melhor habilidade de generalizar do que redes neurais com camadas totalmente conectadas (Nebauer, 1998). Fieres (Fieres;

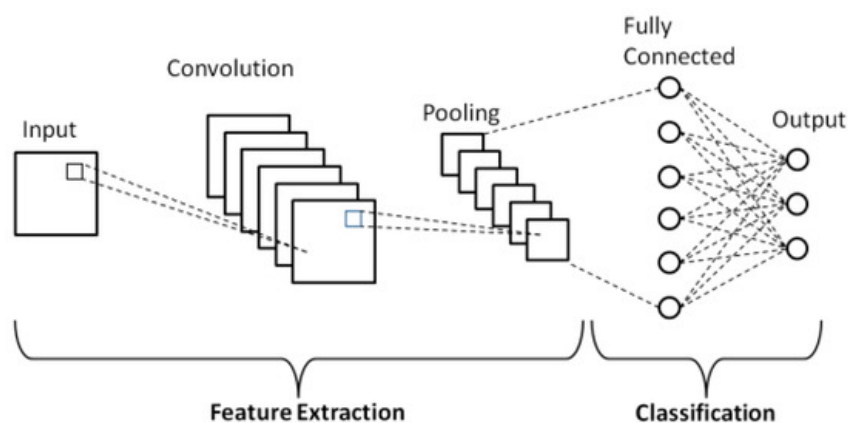
Schemmel; Meier, 2006, p.1) descreve CNNs com o conceito de detectores hierárquicos de características em uma maneira inspirada pela biologia.

Os principais motivos, segundo a literatura, para a arquitetura CNN ser descrita como melhor do que arquiteturas totalmente conectadas, no processamento de imagens são, primeiramente, pelo conceito da criação da CNN, baseado no compartilhamento de pesos, devido ao número de parâmetros a serem treinados reduzir, resultando em uma melhor generalização do modelo (AREL; ROSE; KARNOWSKI, 2010). Devido ao menor número de parâmetros a serem treinados, a CNN reduz a chance de ocorrer *overfitting*.

A arquitetura CNN vem sendo amplamente usado ao longo das últimas décadas, como em classificação de imagens, detecção de objetos e detecção de rostos. De acordo com (INDOLIA et al., 2018, p. 3) as camadas do tipo convolucionais, como o nome já diz, empregam convoluções em uma entrada, por exemplo, uma imagem. As convoluções funcionam como filtros, também chamado de *kernel*, que percorrem a imagem realçando características importantes. O *kernel* é uma matriz de tamanho bem menor do que a imagem, que se desloca de acordo com um parâmetro de *stride*, criando o que é chamado de *feature map*.

Após uma camada convolucional, é geralmente aplicada uma camada de *pooling* com o objetivo de reduzir a informação do *feature map*. Outras camadas convolucionais podem ser empregadas, dependendo da aplicação, por fim, é utilizada uma camada totalmente conectada para a saída da rede neural, sendo um neurônio para cada classe, ou um único neurônio no caso da predição de um valor contínuo, ao estilo regressão. A Fig.2.7 demonstra todo processo explorado.

Figura 2.7 – Exemplo de uma arquitetura de Rede Neural Convolucional.



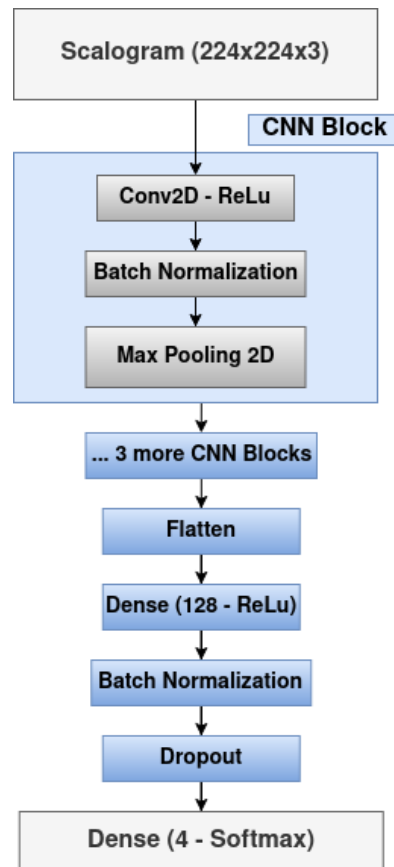
Fonte: (PHUNG; RHEE, 2019).

Uma das arquiteturas utilizadas neste trabalho foi adaptada da proposta de (WANG et al., 2020), como uma das redes neurais exploradas no seu trabalho. A rede neural tem como entrada uma imagem de *Scalogram* no formato 224x224x3, ou seja, três matrizes de 224x224, cada uma referente a um espectro das cores RGB. São então utilizados 4

blocos consecutivos denominados CNN, composto por uma camada convolucional usando a função de ativação “ReLu”, após é aplicada uma camada de normalização para evitar o problema de fuga do gradiente e por fim uma camada “Max Pooling” com o objetivo de reduzir a dimensionalidade.

Depois de passar pelos 4 blocos, é utilizada uma camada do tipo “Flatten” seguido por uma camada totalmente conectada de 128 neurônios, e novamente uma camada de normalização seguido de uma camada de “Dropout”. Por fim, uma camada totalmente conectada com um neurônio por classe, ou seja, quatro neurônios neste caso, é aplicada para computar a saída da rede neural. A arquitetura completa da rede neural é descrita na Fig.2.8.

Figura 2.8 – Rede Neural Convolucional - Arquitetura proposta por Wang.



Fonte: Adaptado de (WANG et al., 2020).

2.3.3.2 GoogLeNet

A segunda arquitetura de rede neural abordada neste trabalho é uma arquitetura desenvolvida por (Szegedy et al., 2015), que venceu a competição *ImageNet Large Scale Visual Recognition Competition 2014* (ILSVRC14) para classificação e detecção de objetos.

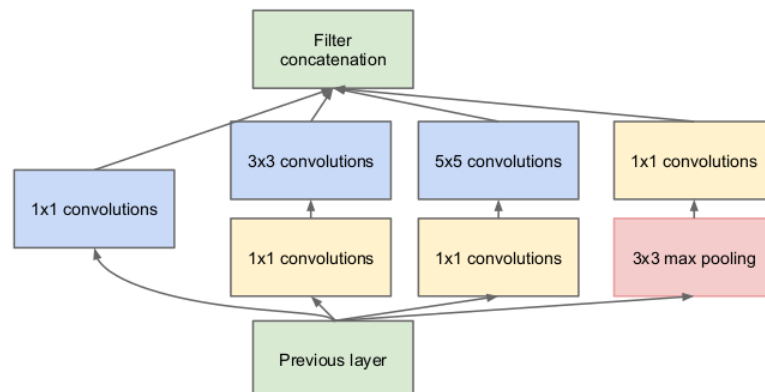
A arquitetura proposta, chamada de GoogLeNet, é uma rede neural profunda com 22 camadas de profundidade, o objetivo da proposta foi melhorar a utilização dos recursos de computação pela rede, ao mesmo tempo que aumenta seu tamanho, profundidade e largura. O objetivo foi alcançado, pois a GoogLeNet tem 12 vezes menos parâmetros do que se comparado a arquitetura AlexNet, sua concorrente.

A GoogLeNet utiliza nove (9) módulos do tipo Inception que são a chave para seu sucesso. Uma das grandes questões ao se construir uma rede neural do tipo convolucional, é qual o tamanho de *kernel*, ou de *stride* deve-se usar, ou então, usar ou não uma camada de Max Pooling para reduzir a dimensionalidade.

Com esta premissa, o módulo Inception foi construído, a arquitetura que tem seu nome baseado no filme de 2010, segundo seus criadores tem o lema “*We need to go deeper*”, uma vez que a mesma utiliza camadas paralelas que são concatenadas em uma camada de saída, que será propagada para um próximo conjunto de camadas. Na versão mais recente o módulo Inception utiliza três camadas convolucionais em paralelo, respectivamente com *kernel* de tamanhos 1x1, 3x3 e 5x5 e uma quarta camada de Max Pooling, onde todas são concatenadas para formar a camada resultante deste bloco.

A Fig.2.9 demonstra o módulo Inception, enquanto a arquitetura completa da GoogLeNet é demonstrada no Apêndice A.

Figura 2.9 – Arquitetura do módulo Inception.



Fonte: (Szegedy et al., 2015).

2.4 ADASYN

Um dos problemas frequentes na área de inteligência artificial é o de classes desbalanceadas, ou seja, em um conjunto de dados com duas classes, a classe “A” representa 97% dos dados, enquanto a classe “B” apenas 3%.

Um modelo capaz de prever com 99% de certeza entre duas classes, “A” ou “B”, pode ser descrito como um sucesso, por alguns autores. Entretanto, avaliar um modelo apenas do ponto de vista da porcentagem de acertos, não é suficiente, no caso descrito, o modelo pode ter apenas classificado todos as classes preditas como “A”, logo em um número considerável de testes, por exemplo, 5.000 testes, onde 4.950 são da classe “A”, os erros em “B” não fariam diferença.

Uma das abordagens para resolver o problema de classes desbalanceadas, é o algoritmo ADASYN (*Adaptive Synthetic Sampling Approach for Imbalanced Learning*), que utiliza uma distribuição ponderada para diferentes exemplos das classes minoritárias, gerando mais dados sintéticos para exemplos das classes minoritárias. O resultado do ADASYN provê uma representação balanceada do conjunto de dados e melhora o aprendizado em relação ao *bias* introduzido pela desequilíbrio de classes. (Haibo He et al., 2008).

2.5 MÉTRICAS DE AVALIAÇÃO

2.5.1 Métricas para Regressão

Dentro do âmbito dos dispositivos não invasivos para estimativa da pressão arterial, são comumente usados dois protocolos de avaliação para a performance. Um deles publicado pela *British Hypertension Society* (BHS) (O'BRIEN et al., 1993) e o outro pela *American Association for the Advancement of Medical Instrumentation* (AAMI) (AAMI/ANSI, 1993). Para cumprir o padrão BHS o método proposto deve atingir ao menos a classe B disposta na Tab.2.1 sendo em relação ao erro médio de todas as predições, 50% dentro de 5 mmHg, 75% dentro de 10 mmHg e 90% dentro de 15 mmHg. No padrão AAMI, o método não pode diferir de uma diferença média absoluta maior do que 5 mmHg ($\Delta p > 5mmHg$) e desvio padrão maior do que 8 mmHg ($SD > 8mmHg$).

Estas métricas são regulamentações internacionais, em que o dispositivo deve alcançar para ser comercializado, olhando do ponto de vista em que o método estima um valor contínuo com precisão de duas casas decimais, ou seja, usando a abordagem de regressão.

Tabela 2.1 – *British Hypertension Society* critério.

Classe	$\leq 5mmHg$	$\leq 10mmHg$	$\leq 15mmHg$
A	60%	85%	95%
B	50%	75%	90%
C	40%	65%	85%
D	Worse than C		

Fonte: Adaptado de (O'BRIEN et al., 1993).

2.5.2 Métricas para Classificação

Entretanto, de acordo com a literatura, há uma segunda abordagem, que é a utilização de métodos de classificação, para então categorizar o estado de uma pessoa. Nesta abordagem é possível avaliar a performance do modelo baseado em algumas métricas.

- **True Positive (TP):** Casos em que o modelo previu corretamente como classe positiva.
- **False Positive (FP):** Casos em que o modelo previu incorretamente como classe positiva.
- **True Negative (TN):** Casos em que o modelo previu corretamente a classe negativa.
- **False Negative (FN):** Casos em que o modelo previu incorretamente a classe negativa.

Baseado nestes dados, é possível construir uma “Matriz de Confusão” para visualizar a performance do modelo, a Fig.2.10 mostra um exemplo de matriz de confusão para duas variáveis preditoras.

Figura 2.10 – Exemplo de Matriz de Confusão.

		Valor Verdadeiro	
		Classe Positiva	Classe Negativa
Valor previsto	Classe Positiva	VP Verdadeiro Positivo	FP Falso Positivo
	Classe Negativa	FN Falso Negativo	VN Verdadeiro Negativo

Fonte: Autor.

Por fim, é possível sumarizar a performance de um modelo, através de indicadores que refletem diferentes aspectos, tais como: Acurácia, Sensibilidade e Especificidade.

- **Acurácia (*Accuracy*)**: Indica uma performance geral do modelo, dentre todas as classificações, quantas o modelo classificou corretamente.

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.5)$$

- **Precisão (*Precision*)**: Dentre todas as classificações de classe Positivo que o modelo fez, quantas estão corretas.

$$Prec = \frac{TP}{TP + FP} \quad (2.6)$$

- **Sensibilidade (*Recall*)**: Dentre todas as situações de classe Positivo como valor esperado, quantas estão corretas.

$$Recall = \frac{TP}{TP + FN} \quad (2.7)$$

- **Especificidade (*Specificity*)**: Dentre todas as situações de classe Negativo como valor esperado, quantas estão corretas.

$$Specificity = \frac{TN}{TN + FP} \quad (2.8)$$

- **F1 Score**: Essa métrica combina precisão e sensibilidade de modo a trazer um número único que indique a qualidade geral do modelo.

$$F1Score = 2 * \frac{Precision * Recall}{Precision + Recall} \quad (2.9)$$

3 TRABALHOS RELACIONADOS

Neste capítulo será abordada uma revisão da literatura, exemplificando trabalhos relacionados a este em questão, onde outros autores usaram diferentes técnicas e abordagens para estimar a pressão arterial.

Na literatura, são duas as abordagens mais comuns usadas para estimar a pressão arterial, a primeira é usando outro sinal biomédico medido simultaneamente, isto é, sincronizado com o sinal de PPG, tal como o sinal de eletrocardiograma (ECG), e a abordagem sem dependência, que é usando apenas o sinal de PPG para estimar a pressão arterial (MARTÍNEZ et al., 2018).

Recentemente muitos autores têm usado algoritmos de inteligência artificial para estimar a pressão arterial não invasiva, mais especificamente algoritmos de *Machine learning* e *Deep Learning*. Zhang e Feng (ZHANG; FENG, 2017) em seu trabalho, extraíram *features* relacionadas à morfologia do sinal de PPG, avaliando cada período de sinal por vez, onde a base de dados utilizada foi a da universidade de Queensland (LIU; GORGES; JENKINS, 2012). Na parte de algoritmos de aprendizado de máquina, foram utilizados o algoritmo *Support Vector Machine* (SVM), Regressão Linear (LR) e uma rede neural artificial com topologia *back propagation* (BPNN). Os principais resultados alcançados foram usando o algoritmo SVM com erro médio e desvio padrão de 11.6 ± 8.2 mmHg e 7.6 ± 6.7 mmHg para SBP e DBP respectivamente.

Khalid et al. (KHALID et al., 2018) em seu estudo também utilizou apenas *features* do sinal de PPG com o mesmo *dataset* da universidade de Queensland (LIU; GORGES; JENKINS, 2012), entretanto o autor menciona que foi feita uma seleção manual dos sinais do *dataset* para evitar sinais de péssima qualidade, que interferissem no desempenho do método proposto. Neste caso, o algoritmo *Regression Tree* teve o melhor desempenho com erro médio e desvio padrão de 0.1 ± 6.5 mmHg e 0.6 ± 5.2 mmHg para SBP e DBP, respectivamente.

Kachuee et al. (KACHUEE et al., 2015), por sua vez, utilizou o método baseado no *Pulse Transit Time* (PTT) que é um sinal extraído da diferença de tempo entre o sinal de PPG e de ECG, ambos sincronizados. Em linhas gerais, o PTT é o tempo de propagação do batimento cardíaco do coração, medido pelo ECG, até os periféricos do corpo onde é medido pelo PPG (KACHUEE et al., 2015), o *dataset* utilizado foi o MIMIC II do banco de dados do Physionet (Physionet, 2020). Os resultados obtidos por este autor em termos de erro médio absoluto e desvio padrão foram de 12.38 ± 16.17 mmHg para SBP e 6.34 ± 8.45 para DBP, e o algoritmo usado foi o SVM.

Nath et al. (NATH; THAPLIYAL; CABAN-HOLT, 2018) ao contrário da maioria das metodologias propostas na literatura, resolveu interpretar o problema como classificação e não o habitual, a regressão, usando o *dataset* MIMIC I (Physionet, 2020) separou as

saídas em quatro *labels* como “Normal”, “Elevado”, “Estágio 1” e “Estágio 2”. Foi utilizado apenas o sinal de PPG e sinais derivados do mesmo, como a primeira derivada do PPG, chamada de *Velocity Plethysmogram* (VPG) e a segunda derivada sendo a *Acceleration Plethysmogram* (APG) como descrito por Elgendi et al. (ELGENDI; LIANG; WARD, 2018). Um dos resultados alcançados utilizando a técnica de classificação por meio do algoritmo *Random Forest* foi 97% de especificidade, 96% de sensibilidade e 97% de precisão na *label* “Elevado”, enquanto nas outras, os resultados foram decaindo, ou na sensibilidade ou na precisão. Em termos de acurácia geral, o autor atingiu 90.8%.

Zhang e Wang (ZHANG; WANG, 2018) em seu estudo, usaram uma abordagem baseada em uma rede neural artificial com topologia *back propagation* (BPNN) e em algoritmos genéticos (GA, do inglês). A base de dados utilizada também foi a da universidade de Queensland (LIU; GORGES; JENKINS, 2012), com extração de *features* de caráter morfológico, semelhante ao de (ZHANG; FENG, 2017), entretanto, foi utilizada uma redução de dimensionalidade com base no valor médio de impacto (MIV, do inglês). Os resultados obtidos por este autor foram de erro médio e desvio padrão de 4.6 ± 6.1 mmHg e 3.8 ± 4.9 mmHg para SBP e DBP respectivamente, usando o algoritmo BPNN e de 4.2 ± 5.6 mmHg e 3.2 ± 4.5 mmHg para SBP e DBP respectivamente, usando o algoritmo GA.

Até o momento todas as abordagens compartilham o mesmo domínio de entrada do método, um sinal de PPG, seja ele pré-processado, na sua forma *raw*, ou um derivado do mesmo, não importa a variação, a entrada é uma série temporal. Entretanto, uma abordagem inovadora vem ganhando espaço na literatura, a utilização de imagens baseadas em sinais de PPG como entrada para redes neurais artificiais.

(LIANG et al., 2018), em seu trabalho, usou a base de dados MIMIC I (Physionet, 2020) para coletar segmentos de sinais de PPG, estes que foram aplicados a Transformada Contínua de Wavelet (CWT, do inglês) utilizando a função Wavelet Morse, resultando em uma imagem RGB denominada *Scalogram* com 224x224 pixels. As imagens foram utilizadas como entrada para a rede neural artificial com arquitetura GoogLeNet (Szegedy et al., 2015). O autor buscou a classificação utilizando 3 classes resultantes, Normotensivos (NH), Pré-Hipertensão (PHT) e Hipertensão (HT). Em termos de resultados, o autor conduziu os experimentos entre duas categorias por experimento, apresentando a performance em termos de F1-Score. O modelo atingiu 80% de F1-Score para classificação entre NH e PHT, 92.55% para classificação entre NH e HT e por fim 82.95% entre (NH+PHT) e HT.

Wang et al. (WANG et al., 2020), por sua vez, também explorou a metodologia baseado em *Scalogram* em seu trabalho, usando sinais fornecidos pelo Centro de Machine Learning e Sistemas Inteligentes da Universidade da Califórnia, Irvine (UCI-ML). O sinal de PPG foi segmentado em partes de 24 segundos, também utilizando a CWT com a função Wavelet Geral de Morse (GMW, do inglês) para geração das imagens. Contudo, o método elaborado pelo autor utiliza o resultado de quatro redes neurais concatenadas para formar uma última responsável pela saída da arquitetura. Onde a primeira rede tem como

entrada as imagens de *Scalogram*, a segunda o sinal de PPG, a terceira o sinal da primeira derivada do PPG, ou VPG e por fim, a última tem como entrada a segunda derivada do sinal de PPG, ou APG, tal abordagem foi denominada *Holistic method*. O autor explorou a classificação em 5 classes, tendo uma acurácia geral de 91.33%.

A Tab.3.1 e Tab.3.2 resumem os resultados dos autores descritos neste capítulo, respectivamente para regressão e classificação.

Tabela 3.1 – Resultados de outros autores usando a abordagem de regressão.

Autor	Dataset	AI	SBP (ME \pm SD)	DBP (ME \pm SD)
(ZHANG; FENG, 2017)	Queensland	SVM	11.6 \pm 8.2	7.6 \pm 6.7
(KHALID et al., 2018)	Queensland*	RT	0.1 \pm 6.5	0.6 \pm 5.2
(KACHUEE et al., 2015)	MIMICII	SVM	12.38 \pm 16.17	6.34 \pm 8.45
(ZHANG; WANG, 2018)	Queensland	GA	4.2 \pm 5.6	3.2 \pm 4.5

Fonte: Autor.

Tabela 3.2 – Resultados de outros autores usando a abordagem de classificação.

Autor	Dataset	Método	AI	Acurácia
(Nath et al., 2018)	MIMIC I	PPG+VPG+APG	RF	90.80%
(LIANG et al., 2018)	MIMIC I	<i>Scalogram</i>	GoogLeNet	82.41%
(WANG et al., 2020)	UCI-ML	<i>Holistic method</i>	MIF-ANN	91.33%

Fonte: Autor.

4 METODOLOGIA

Este capítulo aborda a metodologia usada para o desenvolvimento deste projeto, seguindo a estrutura de elucidar primeiramente as diferentes abordagens implementadas, seguindo para a escolha das bases de dados que foram utilizadas neste trabalho, e por fim o detalhamento do método completo, desenvolvido para estimar a pressão arterial, em termos de SBP e DBP.

4.1 SINGLE PPG WAVE

De acordo com a literatura, a principal abordagem utilizada para estimar a pressão arterial, é extrair informações a partir de cada onda do sinal PPG, isto é, o sinal de PPG sendo periódico, é possível extrair um único período, onde este período, reflete um batimento cardíaco.

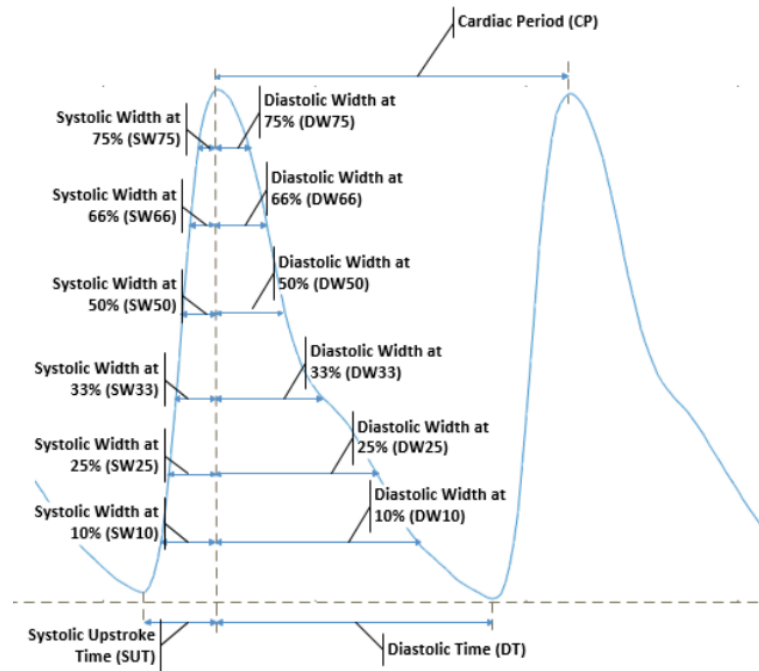
Esta abordagem foi a primeira a ser implementada por este trabalho e foi denominada *Single PPG Wave*. O objetivo da abordagem é processar o sinal de PPG transcrevendo o sinal biomédico para um conjunto de *features* e *labels* que poderão ser interpretadas pelos algoritmos de inteligência artificial.

O método analisa um conjunto de sinais de PPG, referente a um *dataset*, onde primeiramente é extraído cada período do sinal. Para tal, é realizada uma rotina que busca pelos pontos de menor amplitude no sinal de PPG. Uma vez que todos os pontos são conhecidos, é possível delimitar quando um período começa e quando termina, baseado nos picos negativos, ou seja, quando o ciclo se repete.

Com cada período isolado, esta abordagem começa então a extração de *features* do sinal. As *features* extraídas nesta abordagem são todas no domínio do tempo, de caráter morfológico ou estatístico, como por exemplo a extração da área abaixo da curva do sinal PPG, é um valor contínuo com precisão de duas casas decimais, obtido através da integral de Simpson, onde é calculada a integral da curva do sinal PPG.

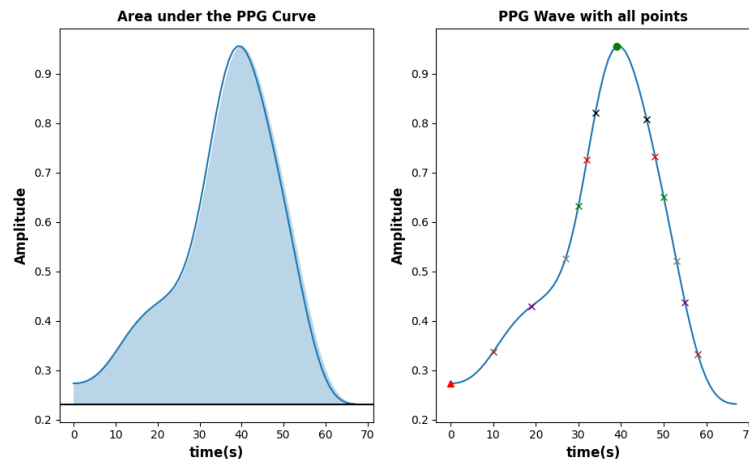
Por outro lado, também é possível a extração dos pontos de largura do sinal, como a largura em 75%, 50% e 25%, que podem conter informações valiosas sobre o estado de saúde ou condição física do paciente. A Fig.4.1 demonstra um exemplo de extração de *features* de caráter morfológico do sinal de PPG, enquanto a Fig.4.2 demonstra um exemplo utilizando a abordagem *Single PPG Wave*.

Figura 4.1 – Exemplo de extração de *features* de caráter morfológico.



Fonte: (KHALID et al., 2018).

Figura 4.2 – Extração de *features* usando a abordagem *Single PPG Wave*.



Fonte: Autor.

As *features* do tipo estatísticas, como *skewness*, variância e curtose, dão uma noção da distribuição do sinal do ponto de vista estatístico, onde de acordo com a literatura são amplamente utilizadas em problemas de regressão. A lista completa de *features* é disponibilizada no Apêndice C.

Do que se refere a pontos positivos e negativos desta abordagem, positivamente o número de diferentes *features* que é possível alcançar usando um único período, bem como é registrado pela literatura uma possível correlação entre a largura de pulso e a pressão arterial como descrito por (AWAD et al., 2007). Como pontos negativos pode

se destacar problemas com falsos picos, onde algoritmos de detecção de pico, por si só, são uma área de estudo, sendo uma tarefa desafiadora em sinais que sofrem com grande quantidade de ruído.


4.2 SLIDING WINDOW

A segunda abordagem implementada, foi a de “janela deslizante” ou *Sliding Window*, como foi denominada. Nesta abordagem, diferentemente da anterior, as *features* são extraídas de uma parte do sinal, ou janela e não de um único período.

Primeiramente são definidos os hiperparâmetros *Size of Window* e *Slice of Window*, que vão configurar o nível de granularidade do método. Então as amostras do sinal são coletadas até concluir o tamanho da janela, ou seja, é coletada uma janela de 60 segundos de amostras de sinal de PPG, por exemplo. Com este subconjunto do sinal são então extraídas as *features*, onde este conjunto de *features* irá compor uma amostra.

O próximo passo é remover uma parte ou “slice” do sinal, baseado no parâmetro setado anteriormente. Para esta implementação foi escolhido remover a parte do início do sinal, ou seja, são removidas “X” amostras do início da janela. O processo então se repete onde o mesmo número de amostras é novamente coletado, ou seja, “deslizando” através do sinal, similar a uma fila do tipo FIFO (*First in First Out*), como demonstra a Fig.4.3.

Figura 4.3 – Exemplo de execução da abordagem *Sliding Window* através do sinal de PPG.



Fonte: Autor.

Na avaliação de pontos positivos e negativos destaca-se, positivamente o controle da granularidade na extração de *features*, bem como, devido a pressão arterial em casos normais, não sofrer alterações abruptas, uma análise baseada em uma parte do sinal pode atenuar *outliers* ou realçar certas características.

Entretanto, para pontos negativos, destaca-se o método de configuração de *labels* no treinamento do modelo, tendo em vista que cada amostra deve ter uma referência de SBP e DBP, e que a uma frequência de amostragem de 100 Hz, uma janela de 60 segundos tem 6.000 referências, que devem ser sumarizadas em um único valor. Para esta implementação, foi utilizado a média aritmética, o que pode interferir tendo em vista que o treinamento do modelo se dá da perspectiva de um único sinal de PPG, que engloba os sinais de todos os diferentes pacientes. Logo, quando em uma janela, existem sinais de dois pacientes diferentes, em condições diferentes, pode ocorrer um erro implícito.

Segundo a revisão da literatura proposta neste trabalho, não foram encontrados trabalhos relacionados que usassem uma abordagem similar a *Sliding Window* no contexto da aferição da pressão arterial, sendo uma abordagem com grandes perspectivas e possibilidades que foi explorada neste estudo. Neste método, foram extraídas *features* no domínio do tempo, domínio da frequência e não lineares, as quais serão mantidas em sigilo devido a aplicações comerciais referentes a empresa Vastmindz, que se propôs em executar esta pesquisa para uma aplicação.

4.3 SCALOGRAM

Contudo, a última metodologia desenvolvida é uma técnica inovadora no âmbito da aferição da pressão arterial, que consiste em mudar por completo o paradigma dos métodos propostos. Como descrito neste trabalho e amplamente na literatura, as redes neurais artificiais vem se destacando na área de AI, tendo como um dos principais domínios de trabalho, processamento de imagens. Como descrito anteriormente no capítulo 3 sobre a revisão da literatura, os trabalhos de (WANG et al., 2020) e (LIANG et al., 2018) já utilizaram esta técnica, e foram uma base de conhecimento inestimável para o desenvolvimento desta abordagem.


O método funciona da seguinte forma, o sinal de PPG é enviado para uma função de janela deslizante, semelhante à descrita na abordagem anterior, entretanto, as “janelas” de sinal, que neste caso foram usados 100 segundos, são convertidos em uma imagem denominada de *Scalogram*. Para tal foi utilizada a Transformada Contínua de Wavelet, onde a função *Wavelet-Mother* foi a Morlet Complexa (CMOR). A Wavelet foi escolhido com base na característica de equilíbrio do plano tempo-frequência relacionado ao Princípio da Incerteza de Heisenberg, como descrito por (DOMINGUES et al., 2016).

No fim do pré-processamento, o resultado é um novo conjunto de dados, onde

foram geradas 143.468 imagens para o primeiro *dataset* e 62.214 para o segundo *dataset* utilizado. As imagens são no espaço de cores RGB de 8 bits e com formato 224x224 pixels, a Fig.4.4 mostra dois exemplos de imagem resultante de duas janelas distintas de sinal de PPG, onde cada uma tem uma referência de SBP e DBP associada.

Um vez que as imagens estão adequadas para o processamento, foram empregadas duas arquiteturas de redes neurais artificiais, ambas já exploradas neste trabalho no capítulo 2, referente a revisão teórica, sendo a arquitetura denominada CNN, e a GoogLe-Net.

Figura 4.4 – Exemplos de imagens *Scalogram* obtidos de duas janelas de sinais de PPG distintas.



Fonte: Autor.

4.4 DATASETS

Para este trabalho foram selecionadas duas bases de dados, sendo uma pública e uma de restrito acesso até o presente momento. As bases de dados devem contar com amostras de sinais PPG, bem como sua referência de SBP e DBP para validação de resultados. A frequência de amostragem de ambas não necessita ser a mesma, pois serão usadas separadamente, e se fosse necessário, uma reamostragem poderia ser implementada. Foram utilizadas duas bases de dados diferentes, com o propósito de em caso de atingir o objetivo de aprovação em ambas, uma melhor comprovação da validade do método.

4.4.1 Queensland *dataset*

Para a base de dados pública, foi utilizado o *dataset* disponibilizado pela universidade de Queensland, denominado *University of Queensland Vital Signs Dataset* (LIU; GORGES; JENKINS, 2012), o qual os dados foram coletados no Royal Adelaide Hospital.

Este *dataset* conta com dados de 32 pacientes, sendo 25 com anestesia geral, 3 com anestesia espinal e 4 sob sedativos, onde para cada paciente foram extraídos dados de sinais como de ECG, PPG, ABP, entre outros e contando com o valor de referência para SBP e DBP. O total de tempo de coleta de dados varia de paciente para paciente, sendo de 13 minutos até 5 horas, contabilizando um total de mais de 40 horas de dados.

Os sinais são extraídos a uma frequência de amostragem de 100 Hz, ou seja, uma amostra a cada 10 milissegundos (ms), por equipamentos como o IntelliVue MP70 e MP30 da Philips, sendo então sinais sincronizados. A Tab.4.1 demonstra os dados extraídos da base de dados de Queensland para cada paciente, em termos de horas e porcentagem em relação ao total de dados disponibilizados, visto que algumas amostras são descartadas por falta de referência ou de artefatos. Contudo este *dataset* provê para este trabalho 14.500.245 amostras, ou seja, 40 horas e 17 minutos de dados.

Tabela 4.1 – Dados coletados para cada paciente do *dataset* de Queensland.

Paciente	Coletado (%)	H. de dados	Paciente	Coletado (%)	H. de dados
01	88.25 %	1h47m	17	84.40%	0h17m
02	38.07 %	0h06m	18	86.57%	0h10m
03	61.55 %	2h33m	19	83.12%	0h19m
04	88.09 %	2h08m	20	86.65%	1h38m
05	31.99 %	1h00m	21	73.39%	0h56m
06	65.36 %	1h09m	22	81.54%	2h13m
07	56.57 %	0h38m	23	84.56%	0h23m
08	85.82 %	0h51m	24	90.94%	0h56m
09	66.95 %	1h12m	25	79.53%	1h24m
10	77.44 %	0h33m	26	60.21%	1h40m
11	91.00 %	1h22m	27	40.80%	1h44m
12	80.81 %	3h59m	28	76.89%	0h57m
13	89.27 %	1h28m	29	87.82%	1h47m
14	84.09 %	1h15m	30	81.61%	0h50m
15	61.80 %	0h16m	31	92.25%	3h14m
16	05.51 %	0h11m	32	86.87%	1h12m

Fonte: Autor.

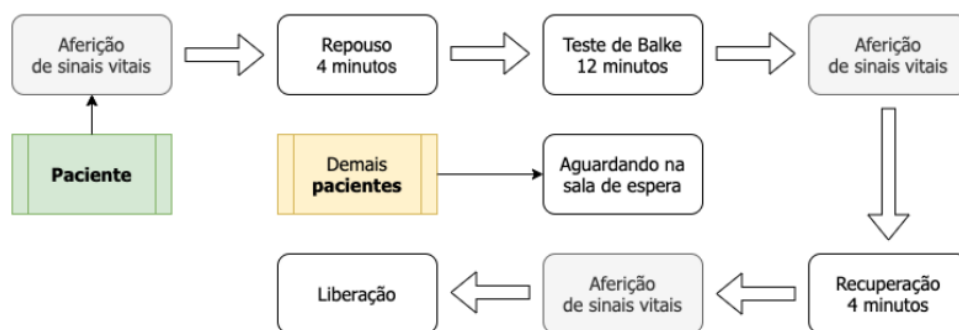
4.4.2 UFSM dataset

O segundo *dataset* utilizado neste trabalho foi desenvolvido na Universidade Federal de Santa Maria (UFSM) em conjunto com o Hospital Universitário de Santa Maria (HUSM) por (ABASCAL, 2020), o qual até o presente momento é restrito aos pesquisadores da instituição, mas segundo o autor futuramente estará disponível para servir de apoio a outras pesquisas. O *dataset* engloba dados pessoais como idade, altura e peso, e também dados clínicos como sinais de PPG e ECG proveniente de indivíduos saudáveis e portadores da Doença Pulmonar Obstrutiva Crônica (COPD, do inglês).

Segundo (ABASCAL, 2020) foram coletados dados de 12 pacientes saudáveis e 12 pacientes com COPD, através de um equipamento embarcado desenvolvido pelo autor, a frequência de amostragem é de 200 Hz, onde cada paciente tem um teste de em torno 22 minutos, totalizando 6.303.520 amostras, ou seja, 8 horas e 45 minutos de dados. A estrutura de diretórios do *dataset* desenvolvido por (ABASCAL, 2020) é descrita no Apêndice B.

Diferentemente do *dataset* de Queensland, estes dados foram coletados com os pacientes em movimento, seguindo o teste de Balke, que é um teste ergométrico com duração máxima de doze minutos, onde o indivíduo é submetido a uma velocidade constante em uma esteira ergométrica, tendo sua inclinação acrescida de uma unidade a partir do terceiro minuto (MENEHELO et al., 2010), o protocolo do experimento é mostrado na Fig.4.5.

Figura 4.5 – Fluxograma do protocolo utilizado para coleta de dados no *dataset* da UFSM.



Fonte: (ABASCAL, 2020).

O *dataset* contém diversas informações relevantes no âmbito da pesquisa, tanto para pressão arterial, quanto para outras pesquisas na área, e será de grande valia para a comunidade acadêmica. Entretanto para este trabalho foram utilizados apenas o sinal de PPG e os dados de referência para SBP e DBP.

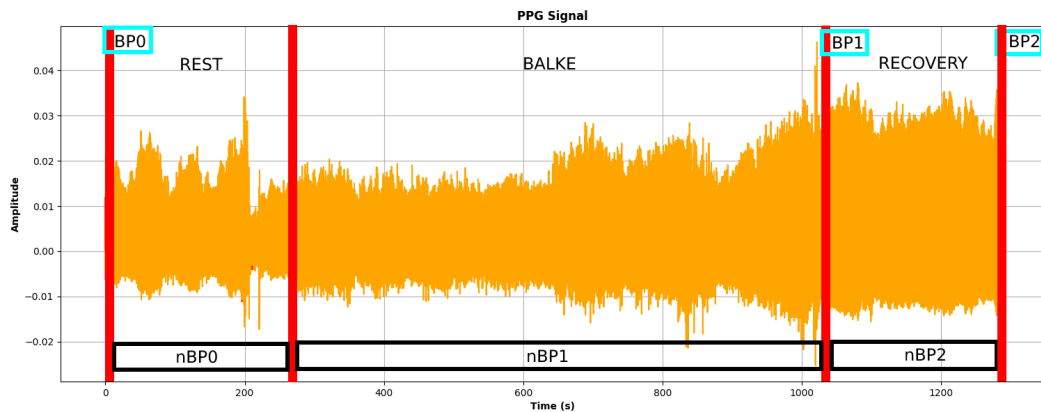
Contudo, como demonstrado na Fig.4.5, a pressão arterial do paciente é aferida em três ocasiões, antes do estágio de repouso, depois do teste de Balke e depois da recuperação. Do ponto de vista da pressão arterial, o ideal seria a contínua aferição, para

que em cada instante de tempo se tivesse uma referência para comparar com o valor predito pelo modelo, entretanto tendo em vista que o experimento é em movimento talvez não fosse possível tal abordagem.

A Fig.4.6, demonstra um sinal de PPG no tempo, onde as marcações em vermelho correspondem ao início de um estágio do experimento, como repouso, Balke ou recuperação. As marcações com sigla “BP” no topo da imagem, demonstram os momentos da aferição da pressão arterial, ou seja, no início do repouso, no final do Balke e no final da recuperação. As marcações na parte de baixo da imagem com sigla “nBP” correspondem a expansão da referência de SBP e DBP para todo o período de tempo delimitado, ou seja, este trabalho, normalizou as três referências fornecidas pelo *dataset*, ao longo do eixo “x” para todo o sinal de PPG.

Para o período de repouso, a chance de ter mudanças abruptas na pressão arterial é bem pequena, visto que o paciente estará sentado e em um estado de relaxamento físico. Contudo, as referências do início do Balke para o seu final, e do início da recuperação para o seu final, terão um erro implícito característico, pois a pressão ao inciar e terminar uma atividade terá uma característica crescente no tempo, onde a curva característica depende de paciente para paciente.

Figura 4.6 – Exemplo de sinal de PPG com marcações para estágios do experimento e referências da aferição da pressão arterial.



Fonte: Autor.

4.5 AMBIENTE DE DESENVOLVIMENTO

Para esta pesquisa, foi utilizada uma máquina virtual (VM, do inglês) para *Data Science* Microsoft Azure fornecida pela empresa Vastmindz de Londres, Reino Unido. A VM executa uma distribuição Linux e possui as GPUs da série NC6s v2, que conta com 6 núcleos e 112 GB de memória RAM.

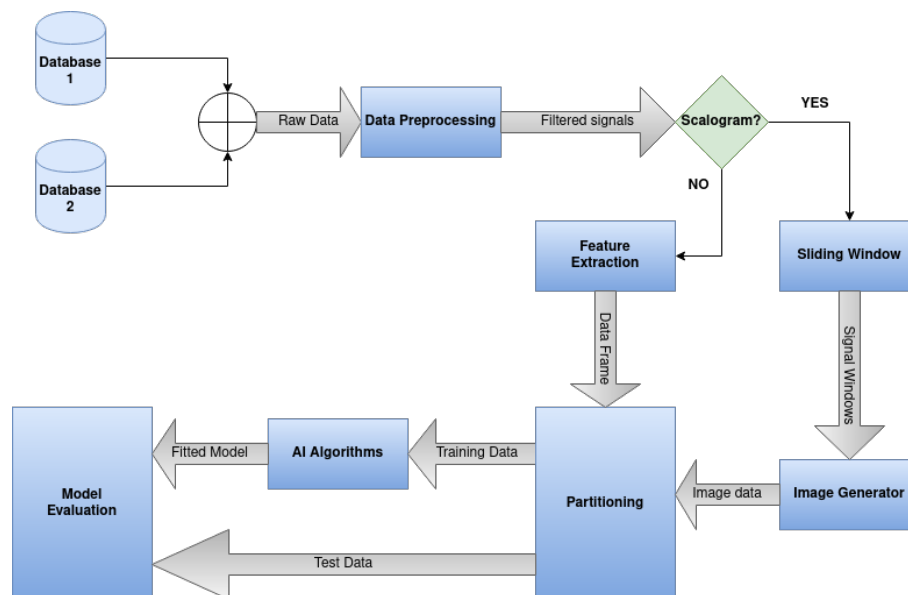
A utilização de uma máquina com grande poder computacional contribui para acelerar o desenvolvimento de cada experimento, tendo em vista que o treinamento dos modelos pode levar horas, devido à grande quantidade de dados.

No entanto, vale ressaltar que embora o treinamento dos modelos tenha um custo computacional alto, por outro lado as predições são executadas em frações de segundos. Contudo, para aplicações práticas, o modelo pode ser exportado para um arquivo JSON, por exemplo, e ser carregado em uma aplicação *low-cost* que só necessita fazer as predições.

4.6 MÉTODO

O método proposto segue três abordagens diferentes, demonstrado pelo fluxograma da Fig.4.7. As abordagens *Single PPG Wave* e *Sliding Window*, seguem a mesma forma de execução, enquanto a abordagem *Scalogram* segue uma abordagem diferente por se tratar de processamento de imagens.

Figura 4.7 – Fluxograma de execução do trabalho proposto.




Fonte: Autor.

A primeira etapa se dá na coleta de dados dos bancos de dados, para uma amostra ser válida, necessita conter uma referência de SBP e DBP, amostras sem referências ou com referências inválidas são descartadas.

Com o sinal *raw* adquirido, a segunda etapa é o pré-processamento de dados, onde o sinal será filtrado usando os filtros Savitzky-Golay com o objetivo de aplicar, o que em processamento de sinais é chamado de *smoothing*, ou seja remover ruídos suavizando


o sinal através de padrões na série temporal. Posteriormente o filtro passa-banda Butterworth, com frequência de corte de 0.5 Hz e 6 Hz, é aplicado para remover frequências indesejadas, provenientes da respiração ou de artefatos do dispositivo da coleta de dados, como descrito no capítulo 2. Por fim, depois de filtrado, o sinal é normalizado usando a abordagem MinMax para estabelecer um padrão em amplitude. As Fig.4.8 e Fig.4.9, demonstram as três etapas de pré-processamento, em termos de sinal *raw*, filtrado e normalizado, respectivamente para um sinal consideravelmente limpo, e para um sinal ruidoso, ambos do *dataset* de Queensland.

Figura 4.8 – Exemplo de pré-processamento em um sinal de PPG limpo do *dataset* de Queensland - Paciente 29.



Fonte: Autor.

Figura 4.9 – Exemplo de pré-processamento em um sinal de PPG ruidoso do *dataset* de Queensland - Paciente 01.



Fonte: Autor.

Com a etapa de pré-processamento concluída, o sinal está pronto para ser proces-

sado. Na etapa de processamento, para as duas primeiras abordagens são extraídas as *features*, que serão a chave para estimar a pressão arterial. Esta provavelmente é a etapa mais complexa, pois cada autor constrói sua própria abordagem, como o número de *features* a serem utilizadas, a maneira que será feita a extração ou qual conjunto de *features* alcança uma melhor performance.

Cada pesquisa busca sua própria metodologia para a extração de “conhecimento” do sinal de PPG, neste trabalho foram implementadas e estudadas duas abordagens diferentes neste âmbito, *Sliding Window* e *Single PPG Wave*, onde ambas as abordagens resultam em um *data frame* de *samples x features*, similar ao descrito na Fig.4.10, entretanto as *features* para cada abordagem são diferentes.

Todavia, a abordagem *Scalogram* necessita de outras duas etapas, primeiramente é aplicado uma outra versão da *Sliding Window*, com o objetivo de separar o sinal de PPG em janelas menores. Após, é convertido o sinal contido nas janelas em uma imagem como descrito ao longo deste trabalho.

Figura 4.10 – Exemplo de *data frame* - *samples x features*.

	w75	w66	w50	w33	w25	w10	SW75	SW66	SW50	SW33	...	DW75	DW66	DW50	DW33	DW25	DW10	areaUnder	r_Value	SBP	DBP
s1	0.18	0.43	0.43	0.43	0.43	0.43	10.0	34.0	34.0	34.0	...	8.0	9.0	9.0	9.0	9.0	9.0	136.52	0.11	113.00	60.00
s2	0.13	0.19	0.39	0.90	0.92	0.92	7.0	11.0	31.0	82.0	...	6.0	8.0	8.0	8.0	8.0	8.0	234.94	0.34	113.00	60.00
s3	0.01	0.01	0.01	0.01	0.01	0.01	1.0	1.0	1.0	1.0	...	0.0	0.0	0.0	0.0	0.0	0.0	73.29	-0.02	113.00	60.00
s4	0.19	0.85	1.03	1.03	1.03	1.03	10.0	53.0	62.0	62.0	...	9.0	32.0	41.0	41.0	41.0	41.0	251.69	0.18	113.00	60.00
s5	0.21	0.42	0.42	0.42	0.42	0.42	16.0	37.0	37.0	37.0	...	5.0	5.0	5.0	5.0	5.0	5.0	101.94	0.11	113.00	60.00
...
s209405	0.17	0.21	0.26	0.33	0.42	0.55	7.0	9.0	11.0	15.0	...	10.0	12.0	15.0	18.0	20.0	23.0	201.52	0.71	111.00	64.00
s209406	0.14	0.21	0.26	0.31	0.39	0.49	6.0	9.0	11.0	14.0	...	8.0	12.0	15.0	17.0	20.0	23.0	186.51	0.76	111.00	64.00
s209407	0.08	0.13	0.20	0.30	0.32	0.36	4.0	6.0	12.0	22.0	...	4.0	7.0	8.0	8.0	8.0	8.0	107.87	0.55	111.00	64.00
s209408	1.12	1.12	1.12	1.12	1.12	1.12	8.0	8.0	8.0	8.0	...	104.0	104.0	104.0	104.0	104.0	104.0	369.95	-0.00	111.00	64.00
s209409	0.10	0.50	0.54	0.57	0.59	0.62	10.0	50.0	54.0	57.0	...	0.0	0.0	0.0	0.0	0.0	0.0	175.13	0.47	121.08	67.77

Fonte: Autor.

Os dados do *data frame* ou do conjunto de imagens, são separados em uma parte para treino e a outra para teste, para este trabalho foram usados, 60%, dos dados para treino e 40% para teste, desta forma o modelo é testado em dados em que ele nunca antes tomou conhecimento. A divisão dos dados se deu desta forma para aumentar o número de testes do modelo, e então melhor corroborar os resultados apresentados.

A última etapa do processo é a criação dos algoritmos de inteligência artificial, onde os modelos de AI são treinados com o conjunto de dados de treinamento, dados estes que são separados em *features* e *labels*, o modelo então assimila o conhecimento de que, aquele conjunto de *features* resultou no determinado valor de SBP ou DBP.

Após o treinamento é possível avaliar a performance do modelo, utilizando como entrada as *features* do conjunto de teste, e extraíndo os valores preditos pelo modelo. Comparando o valor predito com o valor real, é gerado o erro médio, e o desvio padrão de todo o conjunto de treinamento. Um ponto a se ressaltar é que cada instância dos algoritmos é utilizada para estimar SBP ou DBP, sendo uma única saída de dados.

5 RESULTADOS

Este capítulo tem o propósito de demonstrar os resultados encontrados neste trabalho, usando as diversas abordagens detalhadas no capítulo 4.

O capítulo é dividido em cinco seções, onde as três primeiras, seção 5.1, 5.2 e 5.3 demonstram os resultados individuais de cada abordagem desenvolvida por este trabalho, onde cada seção conta com o resultado obtido para cada base de dados separadamente, seguido de uma análise de cada resultado obtido, bem como experimentos que corroboram e validam os resultados da abordagem.

Na sequência, as seções, 5.4 e 5.5, discutem comparações de resultados, primeiramente, resultados entre as abordagens deste trabalho, e posteriormente os melhores resultados deste trabalho com os resultados obtidos por diferentes autores.

5.1 RESULTADOS DA ABORDAGEM *SINGLE PPG WAVE*

Nesta seção, serão demonstrados os resultados usando a abordagem *Single PPG Wave*, descrita no capítulo 4, seção 4.1. Os resultados são separados, primeiramente para a base de dados pública de Queensland e posteriormente para a base de dados da UFSM.

5.1.1 Queensland *dataset*

Usando a base de dados de Queensland como entrada, foi seguido o método proposto no capítulo 4, seção 4.6, usando como abordagem de extração de *features* a *Single PPG Wave*. Nesta abordagem os testes realizados foram em três diferentes algoritmos de AI, os resultados são expressos na Tab.5.1 em métricas de Erro Médio (ME, do inglês) \pm Desvio Padrão (SD, do inglês) e as unidades são em mmHg.

Tabela 5.1 – Resultados usando base de dados de Queensland para diferentes algoritmos de AI na abordagem *Single PPG Wave*.

AI	SBP (ME \pm SD)	DBP (ME \pm SD)
DT	16.02 \pm 21.09	10.04 \pm 11.80
RF	12.43 \pm 13.60	7.80 \pm 7.60
SVM	16.62 \pm 18.12	10.61 \pm 9.30

Fonte: Autor.

É possível observar que os primeiros resultados não foram impactantes, o melhor resultado obtido nesta abordagem, foi utilizando o algoritmo *Random Forest* que teve erro

médio em torno de 12 mmHg para SBP e 8 mmHg para DBP. Do ponto de vista prático, um erro médio de 10 mmHg, para algumas aplicações onde a precisão não é um fator agravante, como por exemplo, *smart bands*, não é exorbitante e um método como o *Single PPG Wave* pode ser utilizado.

Todavia esta abordagem tem potencial para melhores resultados, a performance obtida pode se dar pelo fato do algoritmo de detecção de pico, uma vez que é um ponto crucial no âmbito desta abordagem.

Contudo os resultados alcançados nesta abordagem não atingem o padrão AAMI para dispositivos não invasivos.

5.1.2 UFSM dataset

Da mesma forma, o experimento foi conduzido para a base de dados da UFSM, como descrito no capítulo 4, seção 4.4, o *dataset* da UFSM conta com dois diferentes grupos, um de pacientes saudáveis e um de pacientes portadores de COPD, para este trabalho as análises são efetuadas sobre ambos os grupos sem diferença, do ponto de vista de um único *dataset*, logo o fator da doença em metade do conjunto de dados pode ajudar a diversificar a variedade de amostras fornecidas ao modelo.

Usando a abordagem *Single PPG Wave*, para o *dataset* da UFSM, para três diferentes algoritmos, foram encontrados os resultados descritos na Tab.5.2, em métricas de $ME \pm SD$ e as unidades em mmHg.

Tabela 5.2 – Resultados usando base de dados da UFSM para diferentes algoritmos de AI na abordagem *Single PPG Wave*.

AI	SBP (ME \pm SD)	DBP (ME \pm SD)
DT	11.76 \pm 18.02	6.26 \pm 9.76
RF	10.20 \pm 11.32	5.34 \pm 6.09
SVM	16.85 \pm 15.77	9.95 \pm 7.47

Fonte: Autor.

O comportamento seguiu o mesmo padrão, agora para o *dataset* da UFSM, sendo o melhor resultado utilizando o algoritmo *Random Forest* que obteve erro médio em torno de 10 mmHg para SBP e 6 mmHg para DBP. Entretanto, como abordado anteriormente, resultados com erro abaixo de 10 mmHg, ainda são resultados consideráveis, se a aplicação for algo como *gadgets* para consumidores comuns. Entretanto, mais uma vez, os resultados alcançados nesta abordagem não atingem o padrão AAMI para dispositivos não invasivos.

5.2 RESULTADOS DA ABORDAGEM *SLIDING WINDOW*

Nesta seção, serão demonstrados os resultados usando a abordagem *Sliding Window*, descrita no capítulo 4, seção 4.2. Os resultados são separados, primeiramente para a base de dados pública de Queensland e posteriormente para a base de dados da UFSM.

5.2.1 Queensland *dataset*

Usando a base de dados de Queensland, foi executado o método proposto descrito no capítulo 4, seção 4.6, usando como abordagem de extração de *features* a *Sliding Window*. Nesta abordagem os testes realizados foram principalmente de tamanho de janela, entretanto, foram elaborados testes com diferentes algoritmos, porém somente os que mostraram uma boa performance são apresentados nesta seção.

O tamanho da janela é o principal parâmetro para a abordagem *Sliding Window*, com este valor se tem o controle da granularidade do método, ou seja, janelas maiores usam uma maior quantidade de sinal de PPG para extração de *features*. Entretanto em uma aplicação comercial este parâmetro afeta na quantidade de tempo que o usuário precisará passar durante a coleta até uma primeira aferição.

Neste trabalho foram utilizados quatro tamanhos distintos de janela, sendo tempos em segundos, 30s, 50s, 100s, e 200s. Os resultados para o experimento de tamanho de janela, utilizando o algoritmo *Decision Tree* são apresentados na Tab.5.3 em métricas de Erro Médio (ME, do inglês) \pm Desvio Padrão (SD, do inglês) e as unidades são em mmHg.

Tabela 5.3 – Resultados usando o *dataset* de Queensland para diferentes tamanhos de janelas na abordagem *Sliding Window* usando algoritmo *Decision Tree*.

Tamanho (s)	SBP (ME \pm SD) mmHg	DBP (ME \pm SD) mmHg
30	4.00 \pm 12.12	2.55 \pm 6.93
50	2.16 \pm 9.15	1.36 \pm 4.99
100	0.89 \pm 5.42	0.56 \pm 2.93
200	0.48 \pm 3.81	0.24 \pm 1.70

Fonte: Autor.

É possível notar que os resultados, para quase todas as janelas, se enquadram no padrão AAMI de 5 ± 8 mmHg. As janelas de 30s e 50s ficam maiores do que o padrão em termos de SD na estimativa de SBP, entretanto em termos de ME alcançam aprovação. Nas janelas de 100s e 200s ambas atingem a performance desejada e se enquadram no padrão AAMI.

Para este trabalho, foi escolhido como valor ideal de janela, a de 100s, em termos de custo-benefício, onde o custo seria o tempo de espera para uma predição, entretanto, dependendo da aplicação, 200s ainda é uma janela razoável.

Analisando os resultados em termos do padrão BHS, o método utilizando a janela de 100s atinge o padrão “Classe A”, tanto para SBP, quanto para DBP, como mostram os resultados obtidos, demonstrados pelas tabelas, Tab.5.4 e Tab.5.5, respectivamente para SBP e DBP, onde em média 97% das predições tem erro absoluto menor do que 5 mmHg, em um total de 55.493 predições realizadas.

Tabela 5.4 – Resultados usando métricas BHS para o *dataset* de Queensland usando a abordagem *Sliding Window* - SBP.

Classe	Predições na classe (%)	Somatório das predições (%)
A	96.88%	96.88%
B	1.01%	97.89%
C	0.59%	98.47%
D	1.53%	100%

Fonte: Autor.

Tabela 5.5 – Resultados usando métricas BHS para o *dataset* de Queensland usando a abordagem *Sliding Window* - DBP.


Classe	Predições na classe (%)	Somatório das predições (%)
A	97.40%	97.40%
B	0.97%	98.38%
C	0.47%	98.84%
D	1.16%	100%

Fonte: Autor.

Analisando do ponto de vista gráfico, primeiramente na Fig.5.1 é apresentado um histograma que representa a variedade de referências para SBP e DBP, onde possibilita concluir que o *dataset* contém uma boa representação de amostras.


As figuras, Fig.5.2 e Fig.5.3 representam o gráfico de Bland-Altman, respectivamente para SBP e DBP, que ajuda a dar uma ideia da distribuição das predições, onde o eixo X mostra a média entre o valor predito e o valor real, e o eixo Y a diferença entre ambos.

Figura 5.1 – Histograma da diversidade de referências para SBP e DBP no *dataset* de Queensland.




Fonte: Autor.

Figura 5.2 – Gráfico de Bland-Altman para SBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Decision Tree* e o *dataset* de Queensland.



Fonte: Autor.

Figura 5.3 – Gráfico de Bland-Altman para DBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Decision Tree* e o *dataset* de Queensland.



Fonte: Autor.

5.2.1.1 Análise de overfitting

Um dos maiores questionamentos da área de Inteligência Artificial é sobre o fenômeno de *overfitting* ou sobreajuste do modelo, na prática, significa que o modelo não generaliza e é capaz de prever apenas dados vistos anteriormente. (YING, 2019).

Neste estudo os testes foram realizados com dados nunca antes vistos pelo modelo, sendo separados 60% para treinamento do modelo e 40% para validação. Entretanto, para avaliar e comprovar de uma melhor forma se os resultados atingidos são coerentes, foi elaborado uma análise de *overfitting*, onde este experimento busca reduzir a possibilidade do fenômeno ocorrer. Os experimentos foram de dois tipos, primeiro baseado no algoritmo e segundo por meio de validação cruzada.

5.2.1.2 Análise do algoritmo

A primeira hipótese é de que o algoritmo *Decision Tree* pode criar uma árvore de “n” camadas, onde a demasiada profundidade da árvore faz com que o modelo crie uma predição padrão, generalizando o modelo somente para as amostras treinadas. Para isso, foi trocado o algoritmo para o *Random Forest*, onde este cria “m” árvores, escolhendo aleatoriamente as *features* de cada árvore. Para este experimento foram usadas 1.000 árvores como parâmetro.


Os resultados encontrados para o algoritmo *Random Forest* a uma janela de 100s são mostrados na Tab.5.6. É possível concluir que o erro médio executando o *Random Forest* foi um pouco maior do que em relação ao *Decision Tree*, entretanto o desvio padrão foi substancialmente reduzido, o que pode ser facilmente analisado do ponto de vista do gráfico de Bland-Altman nas figuras Fig.5.4 e Fig.5.5, respectivamente para SBP e DBP.

Tabela 5.6 – Resultados *Random Forest* com janela de 100s usando o *dataset* de Queensland.

Classe	ME \pm SD mmHg
SBP	0.94 \pm 2.31
DBP	0.60 \pm 1.39


Fonte: Autor.

Figura 5.4 – Gráfico de Bland-Altman para SBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Random Forest* e o *dataset* de Queensland.



Fonte: Autor.

Figura 5.5 – Gráfico de Bland-Altman para DBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Random Forest* e o *dataset* de Queensland.



Fonte: Autor.

5.2.1.3 Validação cruzada

Cross Validation ou Validação Cruzada, é uma técnica, descrita amplamente na literatura, para avaliar a capacidade de generalização de um modelo, a partir de um conjunto de dados. O conceito é bastante simples, basta particionar o conjunto de dados em subconjuntos mutuamente exclusivos.

Para este trabalho foi implementada a técnica de validação cruzada *K-Fold*, onde é dividido o conjunto total de dados em K subconjuntos, e a partir daí, um subconjunto é utilizado para teste e os K-1 restantes são utilizados para treinamento do modelo. O processo é realizado K vezes.

A Tab.5.7 demonstra os resultados obtidos utilizando o algoritmo *Decision Tree*, para cada subconjunto, bem como a média final.

Tabela 5.7 – Resultados usando *K-Fold Cross Validation* com janela de 100s, algoritmo *Decision Tree* e o *dataset* de Queensland.

<i>K-Fold</i>	SBP (ME \pm SD) mmHg	DBP (ME \pm SD) mmHg
1	0.63 \pm 4.45	0.38 \pm 2.29
2	0.59 \pm 4.14	0.41 \pm 2.49
3	0.61 \pm 4.46	0.39 \pm 2.49
4	0.60 \pm 4.37	0.38 \pm 2.22
5	0.66 \pm 4.65	0.39 \pm 2.43
6	0.60 \pm 4.57	0.39 \pm 2.32
7	0.59 \pm 4.12	0.49 \pm 2.59
8	0.56 \pm 4.10	0.38 \pm 2.49
9	0.56 \pm 3.89	0.37 \pm 2.29
10	0.60 \pm 4.24	0.41 \pm 2.53
Média	0.60 \pm 4.29	0.39 \pm 2.41

Fonte: Autor.

Através desta análise é possível identificar que o modelo teve uma performance semelhante aos resultados previamente abordados, não havendo nenhum resultado sobresaliente em nenhuma das iterações no teste de validação cruzada. Do ponto de vista de análise, caso houvesse um ou mais resultados atípicos em algumas das iterações, poderia indicar um sobreajuste do modelo, onde o mesmo poderia estar mascarando possíveis erros usando um valor padrão, para as predições de que o modelo não tem conhecimento suficiente para uma resposta.

5.2.1.4 Classificação

Até o presente momento, os resultados abordados seguiam a metodologia da regressão, onde a predição era em termos de valores de ponto flutuante. Entretanto, uma outra maneira de abordar problemas de predição, é do ponto de vista da classificação, ou seja, dado um conjunto de dados, prever a classe em que a amostra se encaixa.

Para a estimativa da pressão arterial também é possível tal abordagem, onde baseado nos níveis de SBP e DBP são classificados de acordo com diretrizes médicas. As diretrizes brasileiras, classificam a pressão arterial de uma pessoa adulta, maior de 18 anos, em cinco (5) categorias, onde os limites são demonstrados pela Tab.5.8. A versão da diretriz utilizada é da 7^a Diretriz Brasileira de Hipertensão Arterial, da Sociedade Brasileira de Cardiologia (MALACHIAS et al., 2016). A categorização é feito sobre os níveis de SBP e DBP, entretanto as categorias para ambas podem divergir, nestes casos adota-se a categoria mais alta.

Um segundo conjunto de diretrizes é descrito pelo Sétimo Relatório da Junta Nacional do Departamento de Saúde e Serviços Humanos dos Estados Unidos ou JNC7

(SCHWARTZ; SHEPS, 1999), onde os níveis de pressão arterial são classificados em quatro (4) categorias, descritas na Tab.5.9.

Ambas as diretrizes foram utilizadas neste trabalho, com o objetivo de ter uma referência no âmbito como trabalho nacional, e uma referência no âmbito internacional, visto que o padrão JNC7 é seguido por vários países. Entretanto, ambas não diferem muito uma da outra, a diretriz brasileira apenas utiliza uma classe a mais para descrever o conjunto, então os resultados esperados para ambas análises podem ser similares.

Tabela 5.8 – Classificação de pressão arterial para indivíduos maiores de 18 anos segundo diretrizes brasileiras.

Classificação	SBP (mmHg)	DBP (mmHg)
Normal	≤ 120	≤ 80
Pré-Hipertensão	121-139	81-89
Hipertensão estágio 1	140-159	90-99
Hipertensão estágio 2	160-179	100-109
Hipertensão estágio 3	≥ 180	≥ 110

Fonte: Adaptado de (MALACHIAS et al., 2016).

Tabela 5.9 – Classificação de pressão arterial para indivíduos maiores de 18 anos segundo diretrizes da JNC7.

Classificação	SBP (mmHg)	DBP (mmHg)
Normal	< 120	< 80
Pré Hipertensão	120-139	80-90
Hipertensão estágio 1	140-159	90-99
Hipertensão estágio 2	≥ 160	≥ 100

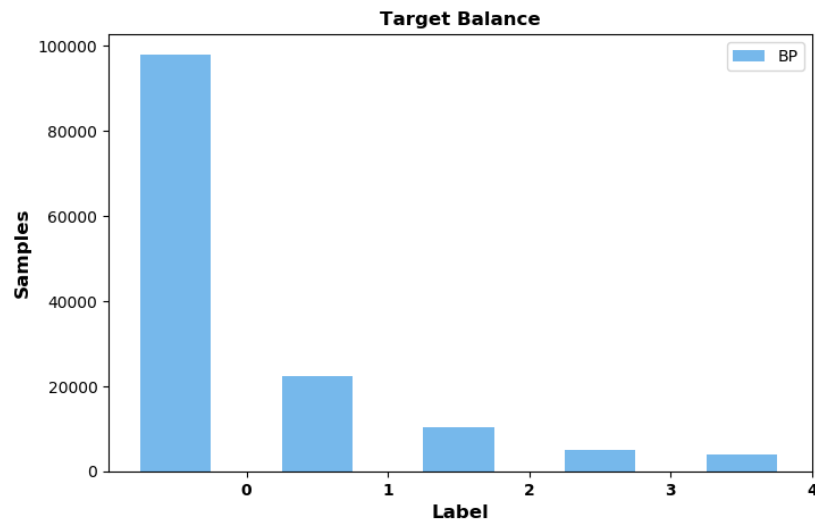
Fonte: Adaptado de (SCHWARTZ; SHEPS, 1999).

As análises desenvolvidas para a abordagem de classificação foram progressivas ao longo do trabalho, envolvendo escolha do algoritmo e seus parâmetros, validação cruzada e a verificação de classes desbalanceadas. Resultados intermediários de cada teste foram suprimidos deste trabalho, que optou por demonstrar uma análise final do método de classificação.

As Fig.5.6 e Fig.5.7 demonstram a distribuição das classes por número de amostras, respectivamente para diretrizes brasileiras e diretrizes da JNC7. Como é possível notar, as classes não estão em equilíbrio de número de amostras, o que pode impactar nos indicadores de performance do modelo, até mesmo mascarando possíveis falhas.


Para as análises apresentadas a seguir, foi utilizado a metodologia com abordagem *Sliding Window*, com janela de 100s, o algoritmo de AI proposto é o *Random Forest*, e foi empregado o algoritmo ADASYN, descrito no capítulo 2, seção 2.4, que permite equalizar o número de referências para cada classe.

Figura 5.6 – Gráfico da distribuição das classes no *dataset* de Queensland segundo as diretrizes brasileiras para classificação de pressão arterial.



Fonte: Autor.

Figura 5.7 – Gráfico da distribuição das classes no *dataset* de Queensland segundo as diretrizes da JNC7 para classificação de pressão arterial.



Fonte: Autor.

Os resultados para as diretrizes brasileiras de pressão arterial são apresentados na Tab.5.10, que demonstra a matriz de confusão, bem como a Tab.5.11 demonstra os resultados dos indicadores de performance.

Tabela 5.10 – Matriz de confusão usando diretrizes brasileiras para o *dataset* de Queensland.

Classe	Normal	Pré-Hiper.	Estágio 1	Estágio 2	Estágio 3
Normal	32.660	104	15	4	8
Pré-Hiper.	191	32.545	535	36	65
Estágio 1	18	270	32.253	105	12
Estágio 2	3	35	112	32.158	3
Estágio 3	5	4	5	7	32.946

Fonte: Autor.

Tabela 5.11 – Resultados usando diretrizes brasileiras para o *dataset* de Queensland.

Classe	Normal	Pré-Hiper.	Estágio 1	Estágio 2	Estágio 3
Normal	99.34%	99.60%	99.83%	99.47%	32.791
Pré-Hiper.	98.75%	97.52%	99.68%	98.13%	33.372
Estágio 1	97.97%	98.76%	99.49%	98.37%	32.658
Estágio 2	99.53%	99.53%	99.88%	99.53%	32.311
Estágio 3	99.73%	99.94%	99.93%	99.83%	32.967
Acurácia			99.06%		

Fonte: Autor.

Os resultados apresentados, demonstram que o modelo atinge um nível de 99% de acertos, tanto na acurácia geral, quanto resultados dentro de cada classe, bem como nas métricas de sensibilidade, que fornece resultados do impacto de uma predição negativa para com a classe positiva, e de especificidade que mostra o impacto de uma predição positiva para com a classe negativa.

Da mesma forma, utilizando as mesmas configurações, foi desenvolvido um experimento seguindo as diretrizes da JNC7 de pressão arterial, os resultados são apresentados na Tab.5.12, que demonstra a matriz de confusão, bem como a Tab.5.13 demonstra os resultados dos indicadores de performance.

Tabela 5.12 – Matriz de confusão usando diretrizes da JNC7 para o *dataset* de Queensland.

Classe	Normal	Pré Hiper.	Estágio 1	Estágio 2
Normal	32.156	116	7	7
Pré Hiper.	219	30.069	520	205
Estágio 1	9	358	31.323	123
Estágio 2	19	57	161	31.383

Fonte: Autor.

Tabela 5.13 – Resultados usando diretrizes da JNC7 para o *dataset* de Queensland.

Classe	Precisão	Sensibilidade	Especificidade	F1-Score	Nº Testes
Normal	99.24%	99.60%	99.73%	99.42%	32.286
Pré Hiper.	98.26%	96.96%	99.44%	97.61%	31.013
Estágio 1	97.85%	98.46%	99.27%	98.15%	31.813
Estágio 2	98.54%	99.25%	99.64%	99.10%	31.620
Acurácia			98.57%		

Fonte: Autor.

Os resultados apresentados, demonstram que o modelo teve performance similar para as diretrizes da JNC7, esta que é adotada pela maior parte dos países, logo é um resultado relevante para este trabalho.

Do ponto de vista de ambos os resultados, uma performance com acerto de 99% pode significar *overfitting*, como já abordado neste trabalho, no entanto topologias como a utilização do algoritmo *Random Forest* e do ADASYN, ajudam a diminuir a chance de tal fenômeno ocorrer, bem como a utilização de classes além do tradicional “verdadeiro ou falso” com 2 classes, neste caso 5 para diretrizes brasileiras e 4 para diretrizes da JNC7, ajudam a corroborar os resultados apresentados.

5.2.2 UFSM *dataset*

Para a base de dados da UFSM, os mesmos experimentos foram executados, primeiramente foram conduzidos os testes de tamanho da janela, usando novamente os tempos em segundos, 30s, 50s, 100s e 200s. Os resultados da análise de tamanho de janela, usando o algoritmo *Decision Tree* são apresentados na Tab.5.14 em métricas de ME \pm SD com as unidades em mmHg

Tabela 5.14 – Resultados usando base de dados da UFSM para diferentes tamanhos de janelas na abordagem *Sliding Window* usando algoritmo *Decision Tree*.

Tamanho (s)	SBP (ME \pm SD) mmHg	DBP (ME \pm SD) mmHg
30	0.21 \pm 2.43	0.13 \pm 1.25
50	0.17 \pm 1.97	0.13 \pm 1.37
100	0.16 \pm 1.91	0.13 \pm 1.33
200	0.19 \pm 2.01	0.13 \pm 1.32

Fonte: Autor.

O *dataset* da UFSM não é tão vasto quanto o de Queensland, tanto em número de amostras quanto em diversidade de referências de SBP e DBP. Entretanto o objetivo deste trabalho desde o início foi atingir o estado da arte, e para isso, testes em diferentes bases de dados ajudam a validar que o método proposto pode ser de grande valia, contribuindo para com a sociedade em geral.

Com os resultados obtidos e demonstrados na Tab.5.14, é possível notar resultados melhores que usando a base de dados de Queensland, com erro médio próximo a 0.15 mmHg e um desvio padrão próximo a 2 mmHg tanto para SBP quanto DBP. Ainda um outro ponto a se notar é de que reduzindo o tamanho da janela, neste *dataset*, não teve um grande impacto na perda de performance do método.

Para a análise em termos do padrão BHS, foi novamente escolhido o tamanho de janela de 100s como ideal, tendo em vista aplicações práticas. Em termos do padrão BHS, o método proposto atingiu o padrão “classe A” também para o *dataset* da UFSM, tanto para SBP quanto para DBP. Os resultados da Tab.5.15 e Tab.5.16 demonstram que para um total de 21.936 testes, 99% das predições tiveram um erro absoluto menor que 5 mmHg.

Este resultado é consideravelmente relevante, devido ao fato de que o *dataset* contém sinais de pacientes saudáveis e portadores de uma doença pulmonar, bem como o fato dos sinais extraídos para a base de dados da UFSM, serem sobre um protocolo que envolve movimento.

Tabela 5.15 – Resultados usando métricas BHS para a base de dados da UFSM usando a abordagem *Sliding Window* - SBP.

Classe	Predições na classe (%)	Somatório das predições (%)
A	99.54%	99.54%
B	0.12%	99.66%
C	0.10%	99.76%
D	0.24%	100%

Fonte: Autor.

Tabela 5.16 – Resultados usando métricas BHS para a base de dados da UFSM usando a abordagem *Sliding Window* - DBP.


Classe	Predições na classe (%)	Somatório das predições (%)
A	99.30%	99.30%
B	0.21%	99.51%
C	0.26%	99.77%
D	0.23%	100%

Fonte: Autor.

Olhando do ponto de vista gráfico, primeiramente na Fig.5.8 é apresentado um histograma que ajuda a explicar a diversidade de referências para SBP e DBP no *dataset*, como é possível notar, a variedade é menor em relação ao de Queensland, principalmente para DBP. Todavia o *dataset* ainda mantém um bom número de amostras dentro das principais faixas, como 60 mmHg, 80 mmHg e 100 mmHg. As figuras Fig.5.9 e Fig.5.10 mostram os gráficos de Bland-Altman usando a janela de 100s e o algoritmo *Decision Tree*. É possível notar que as previsões estão concentradas em torno de uma faixa de erro entre +1 e -1, o que comprova os resultados apresentados anteriormente.


Contudo, também é possível notar alguns *outliers*, que na análise através do erro médio não são evidenciados, porém tem uma grande penalização no desvio padrão.

Figura 5.8 – Histograma da diversidade de referências para SBP e DBP no *dataset* da UFSM.




Fonte: Autor.

Figura 5.9 – Gráfico de Bland-Altman para SBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Decision Tree* e o *dataset* da UFSM.



Fonte: Autor.

Figura 5.10 – Gráfico de Bland-Altman para DBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Decision Tree* e o *dataset* da UFSM.



Fonte: Autor.

5.2.2.1 Análise de overfitting

Com o objetivo de avaliar ou diminuir a chance do *overfitting*, foram desenvolvidas as análises abordadas anteriormente para o *dataset* de Queensland, agora para o conjunto de dados da UFSM, sendo a primeira em termos do algoritmo e a segunda por meio de validação cruzada.

5.2.2.2 Análise do algoritmo

Substituindo o algoritmo *Decision Tree* pelo algoritmo *Random Forest* há um ganho no âmbito da randomicidade, uma vez que, como já abordado, o algoritmo seleciona aleatoriamente as *features* de cada árvore. Para este teste foi usado 100 árvores como parâmetro.

Os resultados encontrados para o algoritmo *Random Forest* a uma janela de 100s são mostrados na Tab.5.17. É possível notar que o erro médio executando o *Random Forest* foi um pouco maior do que em relação ao *Decision Tree*, entretanto o desvio padrão foi reduzido, seguindo o mesmo comportamento observado no *dataset* anterior.


Tabela 5.17 – Resultados *Random Forest* com janela de 100s para o *dataset* da UFSM.

Classe	ME \pm SD mmHg
SBP	0.21 \pm 0.88
DBP	0.14 \pm 0.64

Fonte: Autor.


Analisando o gráfico de Bland-Altman nas figuras Fig.5.11 e Fig.5.12, respectivamente para SBP e DBP, desta vez visualmente se parece que o método com o *Decision Tree* teve melhores previsões do que com o *Random Forest*, e de fato teve, entretanto os pontos dispersos apresentados nos resultados com o *Random Forest* são concentrados entre ± 2 , enquanto os resultados com o *Decision Tree* apresenta valores entre ± 4 , do ponto de vista do desvio padrão, uma função de erro quadrática, estes *outliers* tem uma penalização muito maior.

Figura 5.11 – Gráfico de Bland-Altman para SBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Random Forest* e o *dataset* da UFSM.



Fonte: Autor.

Figura 5.12 – Gráfico de Bland-Altman para DBP na abordagem *Sliding Window* com janela de 100s usando o algoritmo *Random Forest* e o *dataset* da UFSM.



Fonte: Autor.

5.2.2.3 Validação cruzada

A segunda análise mostra os resultados do método quando submetido a técnica de *Cross Validation* anteriormente abordada, o *K-Fold*, onde para este experimento foi usado 10 iterações. Os resultados para cada iteração, bem como a média final, são apresentados na Tab.5.18.

Tabela 5.18 – Resultados usando *K-Fold Cross Validation* com janela de 100s, algoritmo *Decision Tree* e o *dataset* da UFSM.

<i>K-Fold</i>	SBP (ME \pm SD) mmHg	DBP (ME \pm SD) mmHg
1	0.12 \pm 1.72	0.09 \pm 0.98
2	0.10 \pm 1.43	0.10 \pm 1.08
3	0.10 \pm 1.22	0.09 \pm 1.07
4	0.12 \pm 1.75	0.09 \pm 1.06
5	0.15 \pm 1.80	0.10 \pm 1.14
6	0.13 \pm 1.75	0.07 \pm 0.88
7	0.11 \pm 1.46	0.09 \pm 1.02
8	0.13 \pm 1.65	0.08 \pm 0.99
9	0.12 \pm 1.52	0.08 \pm 1.11
10	0.09 \pm 1.18	0.10 \pm 1.15
Média	0.11 \pm 1.54	0.08 \pm 1.04

Fonte: Autor.


Através da análise do *K-Fold* é possível ver que em nenhuma das iterações os resultados divergem e permanecem com erro médio e desvio padrão semelhantes para todos os experimentos, uma vez que para cada valor de K, é utilizado um subconjunto de treino e teste randomicamente selecionado. Contudo, mais uma vez estas análises corroboram e contribuem para a validação dos resultados apresentados neste trabalho.

5.2.2.4 Classificação

Seguindo o fluxo de experimentos desenvolvidos para este trabalho, o próximo é a mudança para a abordagem de classificação. Todavia, tendo em vista que os dados deste *dataset* são de pacientes em diferentes condições de teste, como teste de Balke e recuperação, o presente experimento tem como objetivo avaliar a habilidade do modelo de detectar a mudança de classe, e não de diagnosticar a hipertensão no paciente.


Em um primeiro momento foi analisado a distribuição de dados para cada classe, com o objetivo de observar a diversidade de amostras dentro de cada classe. A Fig.5.13 demonstra o número de amostras para cada classe dentro das diretrizes brasileiras, bem como a Fig.5.14 para as diretrizes da JNC7.

Figura 5.13 – Gráfico da distribuição das classes no *dataset* da UFSM segundo as diretrizes brasileiras para classificação da pressão arterial.



Fonte: Autor.

Figura 5.14 – Gráfico da distribuição das classes no *dataset* da UFSM segundo as diretrizes da JNC7 para classificação da pressão arterial.



Fonte: Autor.

É possível observar que para ambas as diretrizes, as classes mantêm um certo equilíbrio, destacando apenas a classe 4 (Hipertensão Estágio 3) das diretrizes brasileiras com um menor número de amostras.

Entretanto, mesmo com um equilíbrio parcial entre as classes, este trabalho optou por seguir a mesma metodologia explorada na base de dados de Queensland, uma análise utilizando a abordagem *Sliding Window*, com janela de 100s, o algoritmo *Random Forest* e a aplicação do algoritmo ADASYN para balancear as amostras dentro das classes.

Os resultados obtidos usando as diretrizes brasileiras, que permitem classificar a pressão arterial usando 5 classes, são demonstrados pela matriz de confusão na Tab.5.19 e através dos indicadores de performance na Tab.5.20.

Tabela 5.19 – Matriz de confusão usando diretrizes brasileiras para o *dataset* da UFSM.

Classe	Normal	Pré-Hiper.	Estágio 1	Estágio 2	Estágio 3
Normal	5.528	3	0	0	0
Pré-Hiper.	6	5.467	17	2	1
Estágio 1	3	25	5.295	5	0
Estágio 2	1	1	2	5.665	5
Estágio 3	0	1	0	0	5.657

Fonte: Autor.

Tabela 5.20 – Resultados usando diretrizes brasileiras para o *dataset* da UFSM.

Classe	Precisão	Sensibilidade	Especificidade	F1-Score	Nº Testes
Normal	99.82%	99.95%	99.95%	99.88%	5.531
Pré-Hiper.	99.45%	99.53%	99.86%	99.49%	5.493
Estágio 1	99.64%	99.38%	99.91%	99.51%	5.333
Estágio 2	99.88%	99.84%	99.97%	99.86%	5.674
Estágio 3	99.89%	99.98%	99.97%	99.94%	5.658
Acurácia			99.73%		

Fonte: Autor.

Os resultados obtidos demonstram uma taxa de acerto maior do que 99% em todos os indicadores, com acurácia geral de 99.73%, e a última coluna fornecida pela Tab.5.20, demonstra uma média de 5.500 testes realizados por classe, o que é um resultado expressivo para este trabalho. Analisando os resultados, não é uma surpresa o modelo atingir uma boa taxa de acerto na metodologia de classificação, uma vez que, utilizando a regressão, que pode ser descrita como o tarefa muito mais complexa, o erro médio era próximo a 0.2 mmHg.

Do ponto de vista da matriz de confusão, é possível verificar na diagonal principal, as predições corretas em cada classe, bem como identificar que a classe que sofreu com maior número de predições erradas foi a “Estágio 1”, com um total de 33 predições.

O segundo experimento, referente as diretrizes da JNC7, que permitem classificar a pressão arterial em 4 classes, foi elaborado com a mesma configuração e os resultados obtidos, são demonstrados na Tab.5.21, sobre a matriz de confusão, enquanto a Tab.5.22 demonstra os resultados por meio dos indicadores de performance.

Tabela 5.21 – Matriz de confusão usando diretrizes da JNC7 para o *dataset* da UFSM.

Classe	Normal	Pré Hiper.	Estágio 1	Estágio 2
Normal	6.916	10	6	0
Pré Hiper.	4	6.873	11	0
Estágio 1	2	14	6.649	9
Estágio 2	4	3	5	6.355

Fonte: Autor.

Tabela 5.22 – Resultados usando diretrizes da JNC7 para o *dataset* da UFSM

Classe	Precisão	Sensibilidade	Especificidade	F1-Score	Nº Testes.
Normal	99.86%	99.77%	99.95%	99.81%	6.932
Pré Hiper.	99.61%	99.78%	99.86%	99.70%	6.888
Estágio 1	99.67%	99.63%	99.89%	99.65%	6.674
Estágio 2	99.86%	99.81%	99.96%	99.84%	6.367
Acurácia			99.74%		

Fonte: Autor.

Os resultados obtidos neste experimento são semelhantes ao anterior, sendo as análises igualmente semelhantes, entretanto, vale ressaltar um maior número de testes neste experimento, em torno de 6.700, devido ao fato das classes com este conjunto de diretrizes, terem um maior equilíbrio.

Do ponto de vista de resultados, é possível observar uma acurácia geral de 99.74%, semelhante ao experimento anterior, bem como todos os indicadores com taxas maiores do que 99%. A matriz de confusão, demonstra um número maior de *outliers* nas predições, sendo presente em todas as classes preditas, todavia, o maior número de predições erradas em uma classe foi de 16.

5.3 RESULTADOS DA ABORDAGEM SCALOGRAM

Nesta seção, serão demonstrados os resultados usando a abordagem *Scalogram*, descrita no capítulo 4, seção 4.3. Os resultados são separados, primeiramente para a base de dados pública de Queensland e posteriormente para a base de dados da UFSM. Os resultados demonstrados são no âmbito da classificação, utilizando as diretrizes da JNC7 para classificação da pressão arterial.

5.3.1 Queensland dataset

Seguindo o modelo das outras abordagens, o primeiro experimento realizado foi sobre a base de dados de Queensland, que conta com 143.468 imagens, entretanto, antes de começarem as predições, o primeiro teste realizado foi verificar a distribuição de amostras para cada classe, contudo, como esperado, a distribuição seguiu o mesmo padrão demonstrado na abordagem anterior pela Fig.5.7.

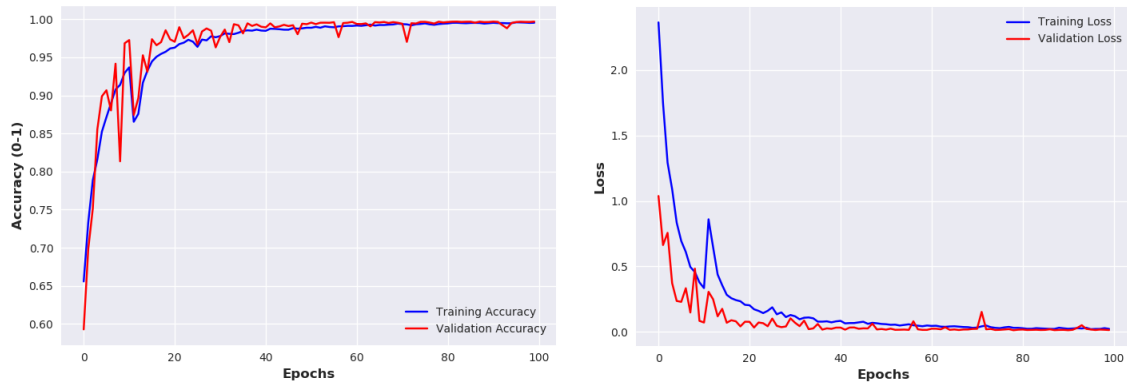
Tendo em vista que as classes não estão balanceadas, foi elaborado uma penalização por classes, isto é, classes com maior número de exemplos tem uma menor importância para os resultados finais, com o objetivo de realizar uma análise com maior credibilidade. O conjunto de dados foi separado de forma randômica, em 60% para treinamento, 20% para validação e 20% para teste. Novamente os conjuntos foram separados de tal forma para que o resultado seja um número considerável de testes. Nesta abordagem, foram utilizadas duas arquiteturas de rede neural artificial, denominadas CNN e GoogLeNet, ambas descritas no capítulo 2 sobre a revisão teórica.

O treinamento das redes neurais foi elaborado de duas formas, utilizando 100 épocas para a rede neural CNN e 20 épocas para a GoogLeNet, estes valores foram escolhidos observando os resultados de testes intermediários, onde foi constatado que a CNN não convergia em apenas 20 épocas. Entretanto um outro ponto de vista, mostra que os

resultados da GoogLeNet, convergem usando somente 20 épocas, o que é um número relativamente baixo, no âmbito do *Deep Learning*.


As figuras, Fig.5.15 e Fig.5.16 demonstram as curvas de aprendizado, no lado esquerdo, do ponto de vista da acurácia, e do lado direito do ponto de vista da função de perda ou *Loss*, respectivamente para as arquiteturas CNN e GoogLeNet.

Figura 5.15 – Curva de aprendizado usando CNN para o *dataset* de Queensland.



Fonte: Autor.

Figura 5.16 – Curva de aprendizado usando GoogLeNet para o *dataset* de Queensland.



Fonte: Autor.

Como demonstrado nas curvas de aprendizado, a arquitetura CNN, que por sua vez é bem mais simples e consequentemente com menor custo computacional do que a GoogLeNet, demorou um número maior de épocas para os resultados convergirem. Entretanto, também é possível verificar que não seria necessário 100 épocas, onde 50 seriam o bastante.

A arquitetura GoogLeNet, por sua vez, teve um treinamento mais estável, onde os resultados rapidamente convergiram. Os resultados obtidos para ambas as arquiteturas utilizando o *dataset* de Queensland, em termos de métricas de desempenho são descritos na Tab.5.23.

Tabela 5.23 – Resultados usando redes neurais para o *dataset* de Queensland.

Rede Neural	Precisão	Sensibilidade	F1-Score	Acurácia
CNN	99.45%	99.58%	99.52%	99.70%
GoogLeNet	99.05%	99.20%	99.12%	99.52%

Fonte: Autor.

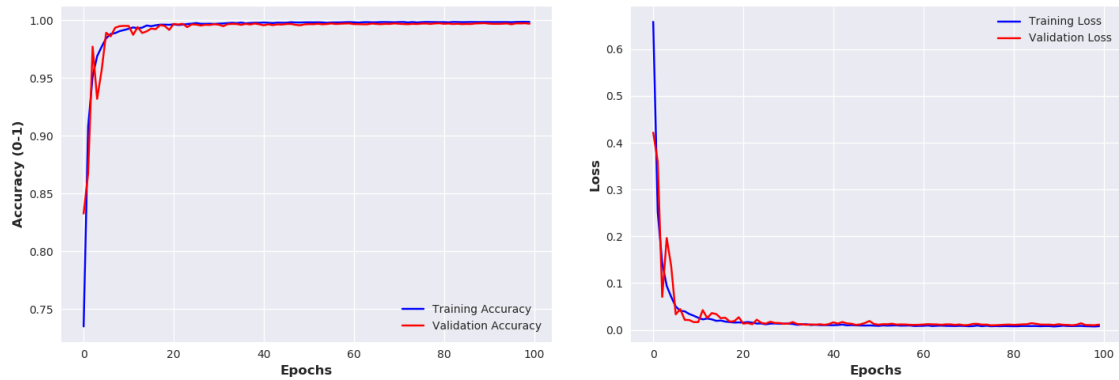
Analisando a Tab.5.23, é possível identificar que os resultados, para ambas as arquiteturas, chegaram a taxas de acertos maiores do que 99% na abordagem *Scalogram*, repetindo performance semelhante a da abordagem anterior, *Sliding Window*. Embora a CNN seja a arquitetura mais simples, conseguiu uma performance um pouco melhor, se comparado a GoogLeNet, todavia, foi necessário um número maior de épocas no treinamento.

5.3.2 UFSM *dataset*

O mesmo fluxo foi desenvolvido para o *dataset* da UFSM, que por sua vez, conta com 62.214 imagens. Do que se refere a distribuição das classes a Fig.5.14 do experimento na abordagem anterior, demonstra que as classes estão razoavelmente equilibradas, e por isso não foi empregado uma penalização por classes neste experimento.


O conjunto de dados foi separado novamente de forma randômica, em 60% para treinamento, 20% para validação e 20% para teste, sendo o treinamento realizado em 100 épocas para a arquitetura CNN e 20 épocas para a GoogLeNet. A Fig.5.17 demonstra as curvas de aprendizado da rede neural CNN, enquanto a Fig.5.18 usando a arquitetura GoogLeNet.

Figura 5.17 – Curva de aprendizado usando CNN para o *dataset* da UFSM.



Fonte: Autor.

Figura 5.18 – Curva de aprendizado usando GoogLeNet para o *dataset* da UFSM.



Fonte: Autor.

Analisando as curvas de aprendizagem das redes neurais, é possível notar que a CNN para o *dataset* da UFSM precisaria de menos de 50 épocas de treinamento para convergir, porém foi adotado um padrão entre os experimentos das bases de dados. Contudo, ambas as redes neurais convergiram no treinamento e com dados da validação. Os resultados utilizando o conjunto de teste são descritos na Tab.5.24.

Tabela 5.24 – Resultados usando redes neurais para o *dataset* da UFSM.

Rede Neural	Precisão	Sensibilidade	F1-Score	Acurácia
CNN	99.65%	99.68%	99.66%	99.58%
GoogLeNet	99.57%	99.58%	99.57%	99.52%

Fonte: Autor.

Do ponto de vista dos indicadores de desempenho, é possível verificar novamente uma taxa de acerto maior do que 99%. Ambas as arquiteturas tiveram um desempenho similar, porém a CNN sendo mais simples, leva vantagem na performance, se comparado a GoogLeNet.

Contudo, resumindo os resultados da abordagem *Scalogram* é possível identificar uma metodologia com possibilidade de alcançar resultados relevantes se comparado aos padrões estabelecidos. Este trabalho exemplificou sua eficácia na classificação de estados da pressão arterial com uma taxa de acerto maior do que 99%. Do que se refere a arquiteturas de redes neurais associadas a abordagem, destaca-se que ambas atingiram aprovação, porém do ponto de vista da performance e custo computacional a CNN leva vantagem, tendo em torno de 15 vezes menos parâmetros se comparado a GoogLeNet. Do ponto de vista do *overfitting* tanto as curvas de aprendizagem, bem como os tipos de camadas associadas as arquiteturas, como camadas convolucionais e de *dropout*, corroboram para com os resultados obtidos por este trabalho.

5.4 COMPARAÇÃO DE RESULTADOS DESTE TRABALHO

Nesta seção, serão abordadas as comparações de resultados dos diferentes métodos e abordagens deste trabalho. Neste trabalho foram desenvolvidas três diferentes abordagens, sendo elas: *Single PPG Wave*, *Sliding Window* e *Scalogram*. A título de comparação, serão usados apenas os resultados sobre a base de dados de Queensland, tendo em vista que os métodos mostraram seguir um padrão em termos de resultados entre as bases de dados e pelo fato da base de dados de Queensland ser pública e de fácil acesso.

Para a abordagem *Single PPG Wave* foram coletados três diferentes resultados baseados em diferentes algoritmos de inteligência artificial. Para a abordagem *Sliding Window*, são cinco diferentes experimentos, com diferença no tamanho da janela e no algoritmo. E por fim na abordagem *Scalogram* são dois os resultados, baseado no tipo de rede neural utilizada, totalizando dez (10) diferentes métodos de estimar a pressão arterial. A relação dos métodos é disponibilizado na lista a seguir:

- *Single PPG Wave + Decision Tree*;
- *Single PPG Wave + Random Forest*;
- *Single PPG Wave + Support Vector Machine*;
- *Sliding Window 30s + Decision Tree*;
- *Sliding Window 50s + Decision Tree*;
- *Sliding Window 100s + Decision Tree*;

- *Sliding Window* 200s + *Decision Tree*;
- *Sliding Window* 100s + *Random Forest*;
- *Scalogram* + CNN;
- *Scalogram* + GoogLeNet.

Dos dez métodos listados, oito (8) deles são relativos à utilização da regressão, isto é, o resultado final é um número, enquanto dois deles são relativos apenas à classificação, onde o resultado final é uma classe. Todavia, a abordagem *Sliding Window* com janela de 100s e algoritmo *Random Forest* foi utilizado também na classificação, logo será somada na comparação dos resultados de ambas as categorias. A comparação dos resultados obtidos para regressão é demonstrada pela Tab.5.25 enquanto a Tab.5.26 mostra os resultados no âmbito da classificação.

Tabela 5.25 – Comparação de resultados do presente trabalho no âmbito da regressão para o *dataset* de Queensland.

Método	AI	SBP (ME \pm SD)	DBP (ME \pm SD)
<i>Single PPG Wave</i>	DT	11.76 \pm 18.02	6.26 \pm 9.76
<i>Single PPG Wave</i>	RF	10.20 \pm 11.32	5.34 \pm 6.09
<i>Single PPG Wave</i>	SVM	16.85 \pm 15.77	9.95 \pm 7.47
<i>Sliding Window</i> 30s	DT	4.00 \pm 12.12	2.55 \pm 6.93
<i>Sliding Window</i> 50s	DT	2.16 \pm 9.15	1.36 \pm 4.99
<i>Sliding Window</i> 100s	DT	0.89 \pm 5.42	0.56 \pm 2.93
<i>Sliding Window</i> 200s	DT	0.48 \pm 3.81	0.24 \pm 1.70
<i>Sliding Window</i> 100s	RF	0.94 \pm 2.31	0.60 \pm 1.39

Fonte: Autor.

Os resultados descritos para a regressão mostram que a abordagem *Sliding Window* foi muito superior a *Single PPG Wave*, onde todos os tamanhos de janela tiveram performance melhor se comparado aos resultados usando a *Single PPG Wave*.

Entre os resultados da abordagem *Sliding Window*, em termos de erro médio e desvio padrão, o melhor resultado obtido foi com a janela de 200s e o algoritmo *Decision Tree*. Todavia, mesmo que o melhor resultado demonstrado neste trabalho foi obtido com o maior valor de janela, segundo experimentos realizados, existe um ponto de saturação em que ao aumentar o tamanho da janela o erro volta a aumentar.

Entretanto, como descrito ao longo deste trabalho, ao avaliar o custo-benefício dos métodos, o resultado escolhido foi o que utiliza a janela de 100s, onde foi avaliado o tempo para a primeira predição que melhor suporta este trabalho. Entre os algoritmos *Decision Tree* ou *Random Forest*, para este trabalho, é preferível o *Random Forest*, pelo fato da randomicidade empregada e pelo desvio padrão mostrar em seus resultados uma menor dispersão das predições.

Tabela 5.26 – Comparação de resultados do presente trabalho no âmbito da classificação para o *dataset* de Queensland.

Método	AI	Precisão	Sensibilidade	F1-Score	Acurácia
<i>Sliding Window</i> 100s	RF	98.47%	98.44%	98.57%	98.57%
<i>Scalogram</i>	CNN	99.45%	99.58%	99.52%	99.70%
<i>Scalogram</i>	GNT	99.05%	99.20%	99.12%	99.52%

Fonte: Autor.

Para os resultados âmbito da classificação, a Tab.5.26 demonstra resultados semelhantes para todos os métodos, e todos eles são descritos, por este trabalho, como um sucesso do ponto de vista de resultados esperados, havendo grandes possibilidades para aplicações reais, sendo de grande valia no âmbito da pesquisa.

Todavia, este trabalho se propõe a escolher o melhor método, e em termos de resultados, a abordagem *Scalogram* com a rede neural CNN teve o melhor aproveitamento com 99.70% de acurácia. Se comparado a sua concorrente direta, GoogLeNet, a CNN ainda leva vantagem do ponto de vista de custo computacional, por ser uma rede neural de menor complexidade, e com menos parâmetros a serem treinados. Entretanto, se comparado com a abordagem *Sliding Window*, em termos de custo computacional necessário, a abordagem *Scalogram* leva desvantagem devido ao fato de ser necessário a geração de uma imagem, e ambas levarem, pelo menos 100 segundos para a primeira predição.

Contudo, novamente a abordagem *Sliding Window* é descrita, por este trabalho, como a melhor abordagem para aferir a pressão arterial, seja utilizando regressão ou classificação.

5.5 COMPARAÇÃO DE RESULTADOS COM DIFERENTES AUTORES

A última seção do capítulo de resultados é destinada a comparação dos melhores resultados obtidos neste trabalho, com trabalhos de outros autores que em seus estudos, buscaram objetivos semelhantes a este trabalho, tentar estimar a Pressão Arterial Sistólica e Pressão Arterial Diastólica de uma pessoa baseado em sinais biomédicos.

Os trabalhos citados nesta seção foram previamente abordados e descritos no capítulo 3. Para efeitos de comparação foram escolhidos dois principais resultados deste trabalho no âmbito da regressão, sendo o da abordagem *Single PPG Wave* utilizando o algoritmo *Random Forest* e da abordagem *Sliding Window* com janela de 100s e o algoritmo *Random Forest*, ambos os resultados são utilizando a base de dados de Queensland, tendo em vista que é uma base de dados pública e de fácil acesso para qualquer autor obter seus resultados. Os resultados são demonstrados na Tab.5.27, sendo os resultados deste trabalho destacados em negrito com o símbolo (").

Tabela 5.27 – Comparação de resultados do presente trabalho com o de outros autores usando regressão.

Autor	Dataset	AI	SBP (ME \pm SD)	DBP (ME \pm SD)
(ZHANG; FENG, 2017)	Queensland	SVM	11.6 \pm 8.2	7.6 \pm 6.7
(KHALID et al., 2018)	Queensland*	RT	0.1 \pm 6.5	0.6 \pm 5.2
(KACHUEE et al., 2015)	MIMICII	SVM	12.38 \pm 16.17	6.34 \pm 8.45
(ZHANG; WANG, 2018)	Queensland	GA	4.2 \pm 5.6	3.2 \pm 4.5
<i>Single PPG Wave "</i>	Queensland	RF	10.20 \pm 11.32	5.34 \pm 6.09
<i>Sliding Window "</i>	Queensland	RF	0.94 \pm 2.31	0.60 \pm 1.39

Fonte: Autor.

Nos resultados do autor (KHALID et al., 2018) é indicado um sinal no *dataset*, devido ao autor ter feito uma seleção manual dos sinais do *dataset* para evitar sinais de péssima qualidade, que interferissem no desempenho do método proposto, como o próprio cita em seu trabalho.

Os resultados mostram que a abordagem *Single PPG Wave* teve resultados melhores do que os resultados dos autores (ZHANG; FENG, 2017) e (KACHUEE et al., 2015) porém teve resultados inferiores se comparado a (KHALID et al., 2018) e (ZHANG; WANG, 2018). Entretanto, a abordagem *Sliding Window* teve resultados melhores que todos os autores, com exceção de (KHALID et al., 2018) que atingiu erro médio de 0.1 mmHg para SBP, no entanto, do ponto de vista do desvio padrão os resultados deste trabalho são mais expressivos.

Os resultados deste trabalho, no âmbito da regressão, atingiram a expectativa, alcançando os padrões AAMI e BHS, para dispositivos não invasivos. Do ponto de vista da comparação com outros autores, este trabalho apostou em uma abordagem que utiliza um subconjunto de sinais ou “janela” para a extração de conhecimento, abordagem esta que, segundo este trabalho, não foi encontrado semelhante na literatura, no âmbito da pressão arterial.

Contudo o método *Sliding Window* é descrito, por este trabalho, como uma abordagem com grandes perspectivas para aplicações práticas, os resultados obtidos neste trabalho ajudam a dar um exemplo da sua aplicação na estimativa da pressão arterial.

Usando a metodologia de classificação, é possível comparar este trabalho com três outros trabalhos selecionados e descritos no capítulo 3. Outra comparação interessante é com os autores (LIANG et al., 2018) e (WANG et al., 2020), que utilizam o método baseado em imagens de *Scalogram* e foram a inspiração para o desenvolvimento desta abordagem neste trabalho. Para esta comparação foram selecionados as três topologias desenvolvidas neste trabalho no âmbito da classificação. A Tab.5.28 demonstra a comparação dos resultados.

Tabela 5.28 – Comparação de resultados do presente trabalho com o de outros autores usando classificação.

Autor	Dataset	Método	AI	Acurácia
(Nath et al., 2018)	MIMIC I	PPG+VPG+APG	RF	90.80%
(LIANG et al., 2018)	MIMIC I	<i>Scalogram</i>	GoogLeNet	82.41%
(WANG et al., 2020)	UCI-ML	<i>Holistic method</i>	MIF-ANN	91.33%
Este trabalho	Queensland	<i>Sliding Window 100s</i>	RF	98.57%
Este trabalho	Queensland	<i>Scalogram</i>	CNN	99.70%
Este trabalho	Queensland	<i>Scalogram</i>	GoogLeNet	99.52%

Fonte: Autor.

No âmbito da classificação, este trabalho teve resultados melhores dos que os autores supracitados, em termos de acurácia geral, com uma taxa de acerto de 98% e 99% nas três metodologias citadas. Do que se refere a melhor, em termos de custo-benefício, este trabalho escolhe a abordagem *Sliding Window* novamente, porém a abordagem de (NATH; THAPLIYAL; CABAN-HOLT, 2018) é muito interessante devido a utilizar *features* extraídas de um único período de PPG, VPG e APG, portanto se entende que o método tenha uma primeira predição em um tempo bem menor do que 100 segundos.

Entretanto, algumas ressalvas são importantes, onde os métodos que utilizam *features* relacionadas a morfologia do sinal, ficam refém de terem como entrada sinais de boa qualidade, ou seja, sem grande quantidade de ruído, bem como se faz necessário etapas mais complexas de pré-processamento. Do ponto de vista da comparação de resultados, este trabalho apenas buscou comparações a título de engrandecer a pesquisa sobre pressão arterial, tendo em vista que os autores utilizam bases de dados diferentes, bem como não é especificado o número de predições nos trabalhos citados.

Contudo, é interessante ver uma comparação entre os trabalhos que utilizam a abordagem baseado em imagens de *Scalogram*, tendo em vista que é uma metodologia não habitual no âmbito da estimativa da pressão arterial, porém com grandes possibilidades, tendo em vista que o poder computacional tem aumentado ao longo dos anos. Outro ponto a se ressaltar, é de que mesmo que a abordagem através de imagens e a arquitetura de rede neural serem os mesmos, o pré-processamento de dados foi diferente, tanto no modo de extração das imagens, onde este trabalho optou por uma metodologia baseada em janela deslizante, bem como o tipo de Wavelet escolhida para a representação.

6 CONCLUSÃO

Este trabalho propôs o estudo e desenvolvimento de diferentes abordagens para a estimativa da pressão arterial, usando como ferramentas, algoritmos de inteligência artificial aplicados ao processamento de sinais biomédicos. Durante o período onde foram conduzidos os estudos que tornaram possível este trabalho, notou-se a importância que um dispositivo capaz de estimar a pressão arterial, de forma contínua e não invasiva, teria para com a sociedade, tanto na vida de pessoas comuns, que apenas desejam manter um histórico de aferições relacionadas a sua saúde, quanto ajudar pessoas que sofrem de doenças cardiovasculares a ter o controle sobre seu estado de saúde.

O enfoque principal do presente trabalho foi o desenvolvimento de três abordagens diferentes para a aferição da pressão arterial, onde todas compartilham a mesma fonte de informação, o sinal de Fotopletismografia. Foram conduzidos um número considerável de experimentos para corroborar a hipótese de que o sinal de PPG, pode ser um substituto confiável para o sinal da ABP, obtido de forma invasiva, na aferição da pressão arterial.

As três abordagens descritas neste trabalho alcançaram resultados interessantes, porém, os resultados obtidos na abordagem *Sliding Window* mostram um erro médio menor do que 1 mmHg, tanto para SBP quanto DBP, sobre duas bases de dados, a da Universidade de Queensland, e a da Universidade Federal de Santa Maria, alcançando tanto o padrão AAMI como também o padrão BHS para dispositivos nesta categoria. Os resultados e análises desenvolvidas neste trabalho concluem que um método utilizando o processamento do sinal de PPG, aliado com algoritmos de inteligência artificial alcançam o objetivo inicial deste trabalho, a criação de um método capaz de aferir a pressão arterial com, uma precisão aceitável, de forma contínua e de forma não invasivo.

Como trabalhos futuros, podem ser explorados melhoramentos das técnicas propostas, como o algoritmo de detecção de pico da abordagem *Single PPG Wave*, redução de dimensionalidade no número de *features* utilizadas, bem como no tamanho da janela, na abordagem *Sliding Window*, e por fim a mudança de paradigma da abordagem *Scalogram*, de classificação para regressão. Do que se refere a todas as abordagens, do ponto de vista de otimização e performance computacional, a mudança de linguagem de programação para uma que oferece um maior desempenho, como por exemplo C++, para aplicações com poder computacional reduzido, se torna uma opção promissora.

REFERÊNCIAS BIBLIOGRÁFICAS

AAMI/ANSI. **Association for the Advancement of Medical Instrumentation, American national standard. Electronic or automated sphygmomanometers.** 1993. Acessado em 23 mar 2020.

ABASCAL, C. **SISTEMA COMPUTACIONAL PARA CAPTURA E AVALIAÇÃO DA VARIABILIDADE DA FREQUÊNCIA CARDÍACA UTILIZANDO FOTOPLETISMOGRAFIA.** 2020. 68 f. Monografia (Dissertação) — PROGRAMA DE PÓS-GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO, Santa Maria, 2020.

AREL, I.; ROSE, D. C.; KARNOWSKI, T. P. Deep machine learning - a new frontier in artificial intelligence research. **IEEE Computational Intelligence Magazine**, v. 5, p. 13–18, 2010.

AWAD, A. et al. The relationship between the photoplethysmographic waveform and systemic vascular resistance. **Journal of Clinical Monitoring and Computing**, 2007.

CHOBANIAN, A. et al. The seventh report of the joint national committee on prevention, detection, evaluation, and treatment of high blood pressure: The jnc 7 report. **Journal of the American Medical Association**, 2003.

Deep AI. **Deep Learning.** 2020. Acessado em 06 Jun 2020. Disponível em: <<https://deepai.org/>>.

DOMINGUES, M. et al. Explorando a transformada wavelet contínua. **Revista Brasileira de Ensino de Física**, scielo, v. 38, 00 2016. ISSN 1806-1117.

ELGENDI, M. et al. Analysis: An optimal filter for short photoplethysmogram signals. **Scientific Data**, 2018.

ELGENDI, M.; LIANG, Y.; WARD, R. Toward generating more diagnostic features from photoplethysmogram waveforms. **MPDI Diseases**, 2018.

Fieres, J.; Schemmel, J.; Meier, K. Training convolutional networks of threshold neurons suited for low-power hardware implementation. In: **The 2006 IEEE International Joint Conference on Neural Network Proceedings.** [S.l.: s.n.], 2006. p. 21–28.

FOUFOULA-GEORGIU, E.; KUMAR, P. **Wavelet Analysis in Geophysics: An Introduction.** [S.l.: s.n.], 1994.

GUYTON, A.; HALL, J. **Guyton and Hall Textbook of Medical Physiology.** [S.l.]: Saunders Elsevier, 2011. 1112 p.

Haibo He et al. Adasyn: Adaptive synthetic sampling approach for imbalanced learning. In: **2008 IEEE International Joint Conference on Neural Networks (IEEE World Congress on Computational Intelligence).** [S.l.: s.n.], 2008. p. 1322–1328.

HöCHT, C. Blood pressure variability: Prognostic value and therapeutic implications. **Hindawi Journal of Healthcare Engineering**, 2013.

INDOLIA, S. et al. Conceptual understanding of convolutional neural network- a deep learning approach. **Procedia Computer Science**, v. 132, 2018.

Janet Ungless. **Whats the Difference Between Diastolic and Systolic Heart Failure?** 2020. Acessado em 05 Jun 2020. Disponível em: <<https://www.everydayhealth.com/>>.

KACHUEE, M. et al. Cuff-less high-accuracy calibration-free blood pressure estimation using pulse transit time. **IEEE International Symposium on Circuits and Systems (IS-CAS)**, 2015.

KAVSAOGLU, A.; POLAT, K.; BOZKURT, M. An innovative peak detection algorithm for photoplethysmography signals: an adaptive segmentation method. **Turkish Journal of Electrical Engineering Computer Sciences**, 2016.

KHALID, S. et al. Blood pressure estimation using photoplethysmography only: Comparison between different machine learning approaches. **Hindawi Journal of Healthcare Engineering**, 2018.

KUMAR, S.; AYUB, S. Estimation of blood pressure by using electrocardiogram(ecg) and photo- plethysmogram(ppg). **Fifth International Conference on Communication Systems and Network Technologies**, 2015.

LIANG, Y. et al. Photoplethysmography and deep learning: Enhancing hypertension risk stratification. **Biosensors MPDI**, 2018.

LIU, D.; GORGES, M.; JENKINS, S. University of queensland vital signs dataset: Development of an accessible repository of anesthesia patient monitoring data for research. **Journal of Anesthesia and Analgesia**, 2012.

MALACHIAS, M. et al. 7th Brazilian Guideline of Arterial Hypertension: Chapter 3 - Clinical and Complementary Assessment. **Arquivos Brasileiros de Cardiologia**, scielo, v. 107, p. 14 – 17, 09 2016. ISSN 0066-782X.

MARTÍNEZ, G. et al. Can photoplethysmography replace arterial blood pressure in the assessment of blood pressure? **MPDI Journal of Clinical Medicine**, 2018.

MENEGHELO, R. et al. III Diretrizes da Sociedade Brasileira de Cardiologia sobre teste ergométrico. **Arquivos Brasileiros de Cardiologia**, scielo, v. 95, p. 1 – 26, 2010.

MIHAI, B.; MIHAI, P. Labview modeling and simulation of the digital filters. 2015.

NATH, R.; THAPLIYAL, H.; CABAN-HOLT, A. Towards photoplethysmogram based non-invasive blood pressure classification. **Proceedings - 2018 IEEE 4th International Symposium on Smart Electronic Systems, iSES 2018**, 2018.

Nebauer, C. Evaluation of convolutional neural networks for visual recognition. **IEEE Transactions on Neural Networks**, v. 9, n. 4, p. 685–696, 1998.

O'BRIEN, E. et al. Short report: An outline of the revised british hypertension society protocol for the evaluation of blood pressure measuring devices. **Journal of Hypertension**, 1993.

Our World in Data. **Causes of Death**. 2020. Acessado em 31 mar 2020. Disponível em: <<https://ourworldindata.org/causes-of-death>>.

PHUNG, V.; RHEE, E. A high-accuracy model average ensemble of convolutional neural networks for classification of cloud image patches on small datasets. **Applied Sciences (Switzerland)**, v. 9, 2019.

Physionet. **MIMIC - Multiparameter Intelligent Monitoring in Intensive Care**. 2020. Acessado em 20 mar 2020. Disponível em: <<https://physionet.org/about/database/>>.

RASCHKA, S.; MIRJALILI, V. **Python Machine Learning**. [S.l.]: Packt Publishing, 2019. 742 p.

SANTANA, S. H. C. de. **Implementação de uma arquitetura microcontrolada para análise do contorno da curva fotopletismográfica**. 2017. 45 f. Monografia (Trabalho de Conclusão de Curso) — Curso de Graduação em Meteorologia, Universidade Federal de Santa Maria, Recife, 2017.

SANTOS, B. et al. Controle de uma plataforma reconfigurável de tecnologia assistiva incorporada a saúde 4.0. **Tecnologia Assistiva. Pesquisa e Conhecimento II**, 2018.

SAVITZKY, A.; GOLAY, M. J. E. Smoothing and differentiation of data by simplified least squares procedures. **Analytical Chemistry**, v. 36, n. 8, p. 1627–1639, 1964.

Schafer, R. W. What is a savitzky-golay filter? **IEEE Signal Processing Magazine**, v. 28, n. 4, p. 111–117, 2011.

SCHWARTZ, G.; SHEPS, S. The seventh report of the joint national committee on prevention, detection, evaluation, and treatment of high blood pressure. **National High Blood Pressure Education Program**, 1999.

SENTURK, U.; YUCEDAG, I.; POLAT, K. Repetitive neural network (rnn) based blood pressure estimation using ppg and ecg signals. **International Symposium on Multidisciplinary Studies and Innovative Technologies, Proceedings**, 2018.

Szegedy, C. et al. Going deeper with convolutions. In: **2015 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. [S.l.: s.n.], 2015.

TAMURA, Y. et al. Wearable photoplethysmographic sensors past and present. **Electronics**, 2014.

WANG, D. et al. Photoplethysmography based stratification of blood pressure using multi information fusion artificial neural network. **2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)**, 2020.

World Health Organization. **World Health Statistics**. 2020. Acessado em 31 mar 2020. Disponível em: <<https://www.who.int/news-room/fact-sheets/detail/hypertension>>.

YING, X. An overview of overfitting and its solutions. **Journal of Physics: Conference Series**, 2019.

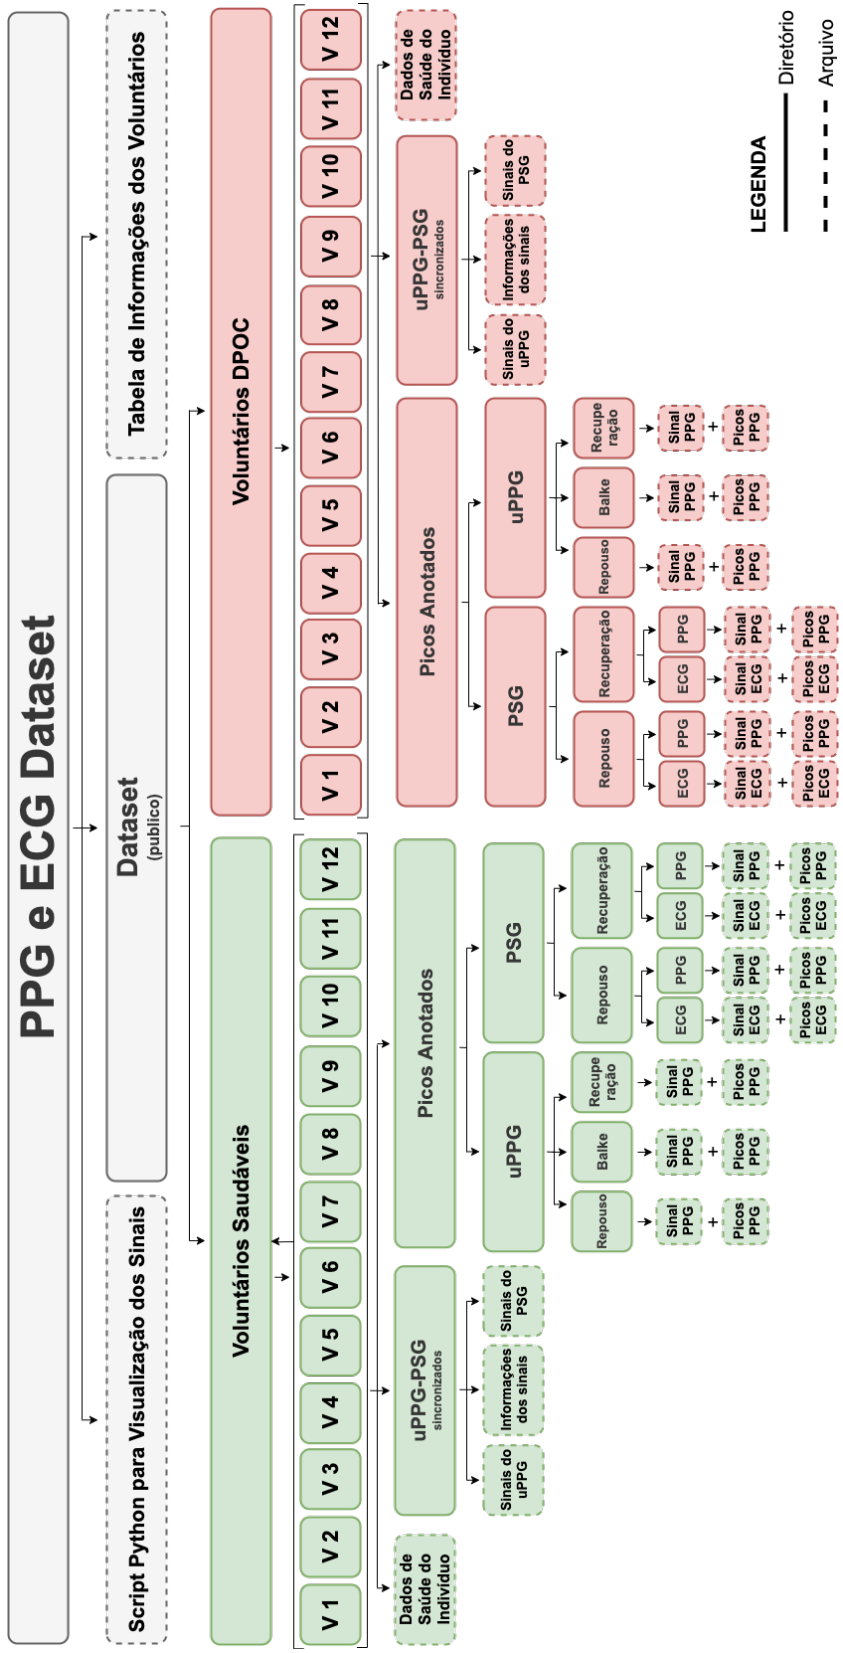
ZHANG, Y.; FENG, Z. A svm method for continuous blood pressure estimation from a ppg signal. **ACM International Conference Proceeding Series**, 2017.

ZHANG, Y.; WANG, Z. A hybrid model for blood pressure prediction from a ppg signal based on miv and ga-bp neural network. **ICNC-FSKD 2017 - 13th International Conference on Natural Computation, Fuzzy Systems and Knowledge Discovery**, 2018.

APÊNDICE A – ARQUITETURA GOOGLNET



APÊNDICE B – ESTRUTURA DE DIRETÓRIOS DO *DATASET* DA UFSM



APÊNDICE C – FEATURES DA ABORDAGEM SINGLE PPG WAVE

Tabela C.1 – Lista de *features* para a abordagem *Single PPG Wave*.

ID	Significado
w75	Largura em 75%
w66	Largura em 66%
w50	Largura em 50%
w33	Largura em 33%
w25	Largura em 25%
w10	Largura em 10%
SW75	Largura Sistólica em 75%
SW66	Largura Sistólica em 66%
SW50	Largura Sistólica em 50%
SW33	Largura Sistólica em 33%
SW25	Largura Sistólica em 25%
SW10	Largura Sistólica em 10%
DW75	Largura Diastólica em 75%
DW66	Largura Diastólica em 66%
DW50	Largura Diastólica em 50%
DW33	Largura Diastólica em 33%
DW25	Largura Diastólica em 25%
DW10	Largura Diastólica em 10%
r75	Razão entre DW75 e SW75
r66	Razão entre DW66 e SW66
r50	Razão entre DW50 e SW50
r33	Razão entre DW33 e SW33
r25	Razão entre DW25 e SW25
r10	Razão entre DW10 e SW10
areaUnder	Área abaixo da curva
rTime	Tempo de subida no eixo X
rValue	Valor de subida no eixo Y
skewness	Skewness
Kurtosis F	Curtose usando definição de Fisher
Kurtosis P	Curtose usando definição de Pearson
Var	Variança
peakValue	Valor de pico
PeaktoPeak	Valor de pico a pico
peakFactor	Fator de pico
diastolicTime	Tempo diastólico